

INSTITUTO TECNOLÓGICO DE AERONÁUTICA

DESENVOLVIMENTO DE UM MODELO DE PREVISÃO DE GERAÇÃO DE ENERGIA ELÉTRICA DE USINAS FOTOVOLTAICAS UTILIZANDO APRENDIZADO DE MÁQUINA

Relatório Parcial de Trabalho de Graduação

Pedro Arthur Sales Rebouças

Orientador: Prof. Dr. Rodrigo Arnaldo Scarpel

Data: 07 de junho de 2026

São José dos Campos - SP

Contents

RESUMO **2**

1 Introdução e Contextualização **3**

1.1 Justificativa e relevância 3

1.2 Objetivo do trabalho 3

2 Revisão de Literatura **4**

2.1 Especificidades da previsão fotovoltaica 4

2.2 Métodos e horizontes de previsão 4

2.3 Modelos de referência e avaliação 5

2.4 Aprendizado de máquina para séries temporais 5

3 Metodologia **5**

3.1 Conjunto de dados 5

3.2 Delimitação do problema 6

3.3 Pré-processamento e variáveis calculadas 6

3.4 Engenharia de *features* 7

3.5 Modelos adotados 7

3.6 Métricas e protocolo de validação 8

4 Planejamento Detalhado e Próximos Passos **8**

4.1 Riscos e pontos de atenção 8

Referências **8**

RESUMO

A elevada penetração da geração fotovoltaica na matriz elétrica brasileira, intensificada no Nordeste, transforma a variabilidade dessa fonte em um desafio operacional concreto, evidenciado pelos cortes de geração (*curtailment*). Este trabalho propõe um modelo de previsão *day-ahead* da geração de usinas fotovoltaicas baseado em aprendizado de máquina, sob abordagem puramente endógena — sem previsões numéricas do tempo, valendo-se apenas de variáveis observadas na usina e de âncoras determinísticas (posição solar e calendário). Utilizam-se dados reais do SCADA de uma usina de aproximadamente 2.5 MW no Nordeste, com cerca de seis meses de cobertura. Comparam-se quatro modelos — XGBoost, SVM, MLP e LSTM — avaliados por RMSE, MAE e *forecast skill score*. Este relatório consolida a revisão de literatura, o pré-processamento, a engenharia de *features* e o protocolo experimental, apresentando o cronograma das etapas restantes.

Palavras-chave: energia fotovoltaica; aprendizado de máquina; previsão de geração; séries temporais; usinas solares.

1 Introdução e Contextualização

A energia solar fotovoltaica consolidou-se como a fonte de maior crescimento da matriz elétrica brasileira. Segundo o Balanço Energético Nacional, a capacidade instalada da fonte alcançou 48468 MW ao final de 2024, expansão de 28.1 % sobre o ano anterior, ao passo que a geração atingiu 70.7 TWh, crescimento de 39.6 % (Empresa de Pesquisa Energética, 2025). Dados mais recentes confirmam a trajetória: a capacidade operacional superou 70.3 GW em abril de 2026, considerando geração centralizada e distribuída (Associação Brasileira de Energia Solar Fotovoltaica, 2026).

Esse desempenho encontra respaldo nas condições físicas privilegiadas do território brasileiro. O Brasil registra potencial teórico médio de $5.276\,\mathrm{kWh\,m^{-2}\,d^{-1}}$ de irradiação horizontal global, superior ao da China (4.127) e ao da Alemanha (2.978), aliado a uma baixa sazonalidade (índice de 1.34 contra 4.37 alemão) que favorece a operação do sistema (Suri et al., 2020). Apesar disso, o grau de aproveitamento ainda é incipiente em termos relativos quando contrastado com a liderança chinesa, da ordem de 1.23 TW instalados (National Energy Administration of China, 2026).

Essa vantagem concentra-se no Nordeste, que reúne os maiores níveis de irradiação do país, em especial o semiárido (Pereira et al., 2017), e a maior parcela da capacidade centralizada outorgada (Associação Brasileira de Energia Solar Fotovoltaica, 2026). O gargalo, contudo, não reside na disponibilidade do recurso, mas em barreiras operacionais, técnicas e institucionais — notadamente a capacidade limitada de transmissão, a escassez de mão de obra qualificada e o ambiente tributário-regulatório (Fratea and Brannstrom, 2017; Queiroz et al., 2020). Um indício concreto desse limite é o aumento do *curtailment*, que em 2025 atingiu cerca de 20.7 % da geração fotovoltaica (Associação Brasileira de Energia Solar Fotovoltaica, 2026).

1.1 Justificativa e relevância

A intermitência da geração fotovoltaica, frequentemente tratada como limitação física, é mais adequadamente compreendida como um problema de informação: a variabilidade só se converte em risco operacional na medida em que é desconhecida ou mal estimada. Melhorar a acurácia da previsão equivale a reduzir a incerteza com que o operador trabalha e, por conseguinte, a margem de reserva térmica que precisa manter. Tian et al. (2023) quantificam esse efeito ao estimar que uma melhoria de 25 % na acurácia da previsão pode reduzir o custo líquido de geração do sistema em 1.56 %. A previsão acurada qualifica, ainda, o planejamento do despacho hidrotérmico — particularmente relevante no Nordeste, em complementaridade com o parque hidrelétrico — e a gestão dos ativos privados, reduzindo a exposição a penalidades de liquidação de diferenças.

1.2 Objetivo do trabalho

O objetivo geral é desenvolver e avaliar comparativamente modelos de aprendizado de máquina para a previsão *day-ahead* da potência ativa gerada por uma usina fotovoltaica

centralizada, sob abordagem endógena, a partir de dados operacionais reais. Como objetivos específicos, destacam-se: (i) caracterizar e pré-processar a base de dados SCADA da usina; (ii) construir o conjunto de *features* respeitando a restrição de não vazamento temporal; (iii) implementar e ajustar os modelos XGBoost, SVM, MLP e LSTM; e (iv) avaliar seu desempenho frente a modelos de referência por meio de métricas padronizadas.

2 Revisão de Literatura

2.1 Especificidades da previsão fotovoltaica

A série de geração fotovoltaica resulta da modulação de uma forçante astronômica determinística — a trajetória solar — por fatores atmosféricos estocásticos, do que decorrem propriedades estatísticas particulares (Markovics and Mayer, 2022). Destacam-se quatro: (i) forte autocorrelação, que fundamenta o uso de defasagens e médias móveis como preditores; (ii) sazonalidade múltipla, com superposição dos ciclos diário e anual, parcialmente conhecível *a priori* por meio de variáveis astronômicas; (iii) truncamento diurno, com fração substancial de observações nulas no período noturno, o que torna a distribuição do alvo fortemente assimétrica (Andrade et al., 2023); e (iv) não-estacionariedade, induzida por degradação dos módulos, *soiling* e falhas de equipamento, o que exige procedimentos de validação que respeitem a ordem cronológica.

2.2 Métodos e horizontes de previsão

Adota-se a partição parcimoniosa de Markovics and Mayer (2022), que agrupa as abordagens em físicas, estatísticas e híbridas, compreendendo os métodos de aprendizado de máquina como subconjunto das estatísticas (orientadas por dados). Os métodos físicos baseiam-se em cadeias de modelos que descrevem analiticamente a conversão da irradiância em potência, dispensando dados históricos, mas com acurácia tipicamente inferior à das abordagens orientadas por dados (Andrade et al., 2023). Os métodos estatísticos estimam, a partir de dados históricos, uma função que minimiza uma perda sobre o conjunto de treinamento, sendo as técnicas de aprendizado de máquina as mais empregadas e, frequentemente, as de melhor desempenho (Markovics and Mayer, 2022).

Quanto ao horizonte, a literatura distingue quatro faixas: altíssimo curto prazo (*nowcasting*), curto prazo (intra-dia), um dia à frente (*day-ahead*) e médio a longo prazo (Tian et al., 2023). A previsão *day-ahead* ($24-48$ h à frente) é a de maior relevância para a programação do despacho e a comercialização (Markovics and Mayer, 2022). Nessa faixa, distinguem-se duas estratégias: a baseada em previsão numérica do tempo (NWP) e a puramente endógena, que projeta a geração do dia seguinte exclusivamente a partir do histórico observado na usina, explorando a autocorrelação e os padrões cíclicos (Andrade et al., 2023). A abordagem endógena, adotada neste trabalho, dispensa o acesso a previsões NWP ao custo de acurácia tipicamente inferior.

2.3 Modelos de referência e avaliação

A literatura recomenda contextualizar o desempenho por comparação com um modelo de referência (*baseline*) (Sarmas et al., 2022), formalizada pelo *forecast skill score*, $\text{skill} = 1 - \text{RMSE}_{\text{modelo}}/\text{RMSE}_{\text{ref}}$. A persistência ingênua é inadequada para a geração fotovoltaica em horizontes de horas, por ignorar o ciclo diário; recomenda-se, em seu lugar, a persistência inteligente (*smart persistence*), que incorpora um modelo de céu claro e constitui a referência canônica da área (Markovics and Mayer, 2022; Sarmas et al., 2022). Um modelo estatístico linear é usualmente acrescentado como referência de complexidade intermediária, isolando o ganho atribuível à modelagem não linear.

2.4 Aprendizado de máquina para séries temporais

O ajuste de um modelo consiste em selecionar, em uma classe de funções $\mathcal{F}$, aquela que minimiza uma função de perda sobre o treino; o objetivo último, porém, é minimizar o risco esperado sobre dados não vistos. No caso de séries temporais, a hipótese de observações independentes e identicamente distribuídas é violada, e a aproximação só se transfere ao futuro na medida em que a estrutura estatística permaneça estável. A formulação supervisionada é tipicamente obtida por janela deslizante, em que o vetor de preditores é composto por valores defasados e covariáveis disponíveis até o instante de emissão, sob a exigência crítica de que nenhuma informação posterior integre esse vetor, sob pena de vazamento de informação (*data leakage*). O controle do compromisso viés–variância é exercido sobretudo por regularização, que penaliza a complexidade do modelo. Por fim, a estimativa de desempenho deve empregar validação cruzada adaptada — *walk-forward* ou janela deslizante — que preserve a causalidade temporal, evitando o vazamento que o *K-fold* convencional, com particionamento aleatório, introduziria (Kappler et al., 2024).

3 Metodologia

3.1 Conjunto de dados

Os dados provêm do sistema SCADA de uma usina solar fotovoltaica centralizada real, em operação, localizada no Nordeste do Brasil. A usina é composta por dez inversores de potência nominal da ordem de 275 kW cada, totalizando aproximadamente 2.5 MW em corrente alternada. O período de cobertura estende-se por cerca de 182 dias (dezembro de 2025 a junho de 2026), com aproximadamente 2.6e5 registros por variável na grade de um minuto. Registra-se, como limitação assumida explicitamente, que a janela não cobre um ciclo sazonal anual completo, o que pode restringir a representatividade do modelo treinado.

A grandeza-alvo é a potência ativa total P_{ac}, obtida pela soma das potências individuais dos dez inversores. As demais grandezas registradas são organizadas na Tabela 1.

Table 1: Variáveis registradas pelo sistema SCADA da usina.

Grupo	**Variável (símbolo)**	**Resolução**
Elétrica	Potência ativa por inversor ($P_{ac,i}$, $\times 10$)	1 min
Irradiância	Plano inclinado — POA (G_t)	1 min
	Global horizontal — GHI (G_h)	1 min
	Refletida (G_r)	1 min
Temperatura	Ambiente (T_{amb})	1 min
	Do módulo (T_{mod})	1 min
	Interna por inversor ($T_{inv,i}$, $\times 10$)	5 min
Outras meteo.	Umidade relativa (UR)	1 min
	Velocidade do vento (v_w)	5 min
	Direção do vento (d_w)	5 min

A disponibilidade simultânea de G_t e G_h dispensa modelos de transposição, cujas incertezas se propagariam pela cadeia de conversão; analogamente, a medição direta de T_{mod} elimina a necessidade de estimá-la por correlações empíricas.

3.2 Delimitação do problema

Fixam-se três elementos. A **grandeza-alvo** é P_{ac}, na resolução horária. O **horizonte** é *day-ahead*: fixado o instante de emissão t, busca-se prever o conjunto $\{\hat{P}_{ac}(t+h)\}_{h\in\mathcal{H}}$, com $\mathcal{H}$ compreendendo os passos horários diurnos do dia seguinte ($24-48$ h à frente). A **classe de informação** é endógena: o vetor de preditores admite apenas informação disponível até t, sem previsões NWP futuras. O vetor combina, assim, variáveis defasadas das grandezas observadas (que reintroduzem a memória temporal) e variáveis determinísticas conhecíveis *a priori* (ângulos solares e calendário), estas últimas constituindo a âncora física da abordagem.

3.3 Pré-processamento e variáveis calculadas

A potência total é obtida por $P_{ac}(t) = \sum_{i=1}^{10} P_{inv,i}(t)$, exigindo-se a presença simultânea das dez leituras para validar o instante, o que evita viés sistemático de subestimação (apenas 0.006 % dos registros resultaram faltantes). A posição solar é calculada pelo algoritmo SPA de Reda and Andreas (2004), implementado na biblioteca `pvlib` (Holmgren et al., 2018), da qual se derivam a elevação γ_s, o ângulo zenital θ_z e o azimute ψ_s.

A cadeia de pré-processamento (Tabela 2) foi ordenada de modo que o tratamento de *outliers* preceda a reamostragem, impedindo que picos espúrios contaminem as médias horárias. A detecção de anomalias baseou-se em critérios físicos e geométricos — não estatísticos —, conferindo maior defensabilidade ao procedimento. Identificou-se, por exemplo, $G_r = 6553.5\,\mathrm{W\,m^{-2}}$, valor correspondente exatamente a 65535/10, isto é, ao estouro de um registrador de 16 bits; e valores nulos espúrios de T_{inv} no período noturno, associados a inversores inativos. Adotou-se a elevação solar γ_s como critério-mestre para anulação das irradiâncias noturnas e para o recorte diurno final, por ser função de-

terminística e imune a ruído de sensor. Após o recorte ($\gamma_s > 0$), restaram 2207 horas diurnas.

Table 2: Etapas do pré-processamento, na ordem de aplicação.

#	**Operação**	**Critério adotado**
1	Alinhamento temporal	Indexação cronológica; verificação da grade de 1 min
2	Tratamento de *outliers*	Invalidação pontual por limites físicos e geometria solar
3	Reamostragem horária	Média condicionada a piso mínimo de leituras válidas
4	Tratamento de faltantes	Interpolação temporal curta; preenchimento limitado
5	Recorte diurno	Seleção de registros com $\gamma_s > 0$

3.4 Engenharia de *features*

Adota-se o **esquema de previsão direto**, em que se ajusta um modelo independente f_h para cada horizonte: $\hat{P}_{ac}(t+h) = f_h(x_t)$. A escolha justifica-se por não acumular erro ao longo do horizonte (ao contrário da estratégia recursiva), por acomodar naturalmente a descontinuidade noturna e por tornar explícita a restrição de não vazamento, já que a defasagem endógena mais recente admissível para prever $t+h$ é exatamente de h horas (Taieb et al., 2012).

A seleção das defasagens apoiou-se na análise das funções de autocorrelação parcial (FACP) computadas entre dias homólogos na mesma hora, removendo por construção o efeito do ciclo diurno determinístico (já capturado pelas variáveis solares) e evitando dupla contagem. A FACP indicou concentração da informação preditiva nas defasagens de um a três dias. Variáveis circulares (hora do dia, dia do ano, azimute e direção do vento) foram codificadas por pares seno–cosseno, preservando a continuidade do domínio. As *features* numéricas foram padronizadas por *z-score* para os modelos sensíveis à escala (SVM, MLP, LSTM), com parâmetros estimados exclusivamente sobre o conjunto de treino, em consonância com o protocolo de validação temporal.

3.5 Modelos adotados

Selecionaram-se quatro famílias com vieses indutivos contrastantes, representativas da literatura recente (Tian et al., 2023):

- **XGBoost** — *ensemble* aditivo de árvores ajustadas sequencialmente (Chen and Guestrin, 2016); invariante a transformações monotônicas, robusto à multicolinearidade e competitivo no volume de dados disponível.
- **SVM** — regressão por vetores de suporte com *kernel* RBF; paradigma de margem e otimização convexa, com solução global garantida.

- **MLP** — rede *feedforward*; aproximador universal e referência arquitetural mínima frente à rede recorrente.
- **LSTM** — rede recorrente para dependências temporais de longo alcance; referência obrigatória de comparação, embora sua elevada capacidade tenda a ser limitada pelo regime de poucos dados (Tian et al., 2023).

3.6 Métricas e protocolo de validação

As métricas primárias são a raiz do erro quadrático médio (RMSE) e o erro absoluto médio (MAE), reportadas conjuntamente por capturarem aspectos distintos do erro; o RMSE, mais sensível a desvios grosseiros, é o critério principal, e o MAE caracteriza a forma da distribuição. Acrescenta-se o *forecast skill score* relativo à persistência inteligente, cujo modelo de céu claro é estimado pela `pvlib`. Como segundo *baseline*, emprega-se a regressão linear sobre o mesmo vetor de preditores. O protocolo de validação é o *walk-forward*, que preserva a ordem cronológica e previne tanto o vazamento temporal quanto, pela abordagem endógena, o vazamento de

4 Planejamento Detalhado e Próximos Passos

As etapas de fundamentação teórica, caracterização dos dados, pré-processamento, engenharia de *features* e definição do protocolo experimental encontram-se concluídas. As etapas restantes concentram-se na implementação, no ajuste e na avaliação comparativa dos modelos, além da redação dos capítulos de resultados e conclusão, conforme o gráfico de Gantt da Figura 1.

4.1 Riscos e pontos de atenção

Três pontos merecem acompanhamento, antecipando questionamentos da banca: a **cobertura temporal limitada** (cerca de seis meses), que não abrange um ciclo sazonal completo e cujas implicações sobre a generalização serão discutidas explicitamente; o **desempenho esperado da LSTM**, que tende a ser superada por métodos baseados em árvores em regimes de poucos dados (Tian et al., 2023) — resultado de interesse sobre a adequação de cada classe ao regime de plantas em início de operação; e a **resolução do acordo de confidencialidade** com o operador, necessária antes da identificação do município e do estado na versão final.

Referências

C. H. T. Andrade et al. How does neural network model capacity affect photovoltaic power prediction? a study case. *Sensors*, 23 (3):1357, 2023.

Associação Brasileira de Energia Solar Fotovoltaica. Infográfico absolar nº 91: energia solar fotovoltaica no brasil. Technical report, ABSOLAR, São Paulo, 2026.

T. Chen and C. Guestrin. Xgboost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, pages 785–794, 2016.

Empresa de Pesquisa Energética. Balanço energético nacional 2025: Relatório síntese –

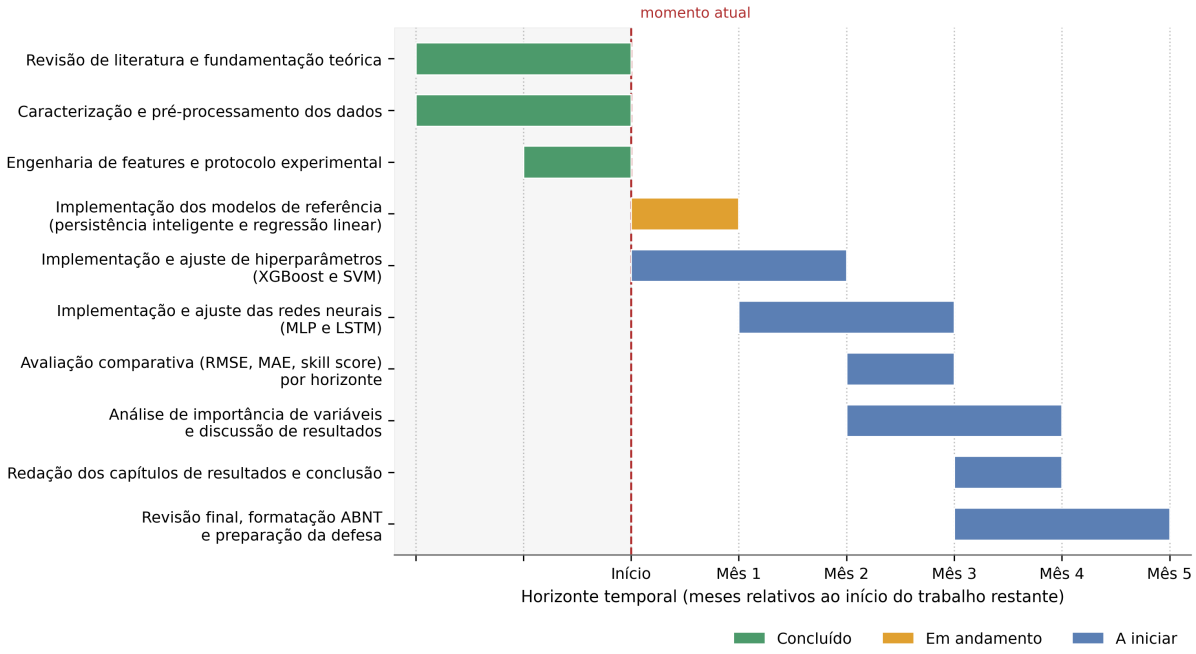


Figure 1: Gráfico de Gantt das etapas restantes do trabalho. As barras em verde indicam atividades já concluídas; em âmbar, a etapa em andamento; em azul, as etapas a iniciar.

ano base 2024. Technical report, EPE, Rio de Janeiro, 2025.

C. A. Fratea and C. Brannstrom. Stakeholder subjectivities regarding barriers and drivers to the introduction of utility-scale solar photovoltaic power in brazil. *Energy Policy*, 111: 346–352, 2017.

W. F. Holmgren, C. W. Hansen, and M. A. Mikofski. pvlib python: a python package for modeling solar energy systems. *Journal of Open Source Software*, 3(29):884, 2018.

T. Kappler et al. Detection of shading for short-term power forecasting of photovoltaic systems using machine learning techniques. *EPJ Photovoltaics*, 15:17, 2024.

D. Markovics and M. J. Mayer. Comparison of machine learning methods for photovoltaic power forecasting based on numerical weather prediction. *Renewable and Sustainable Energy Reviews*, 161:112364, 2022.

National Energy Administration of China. Statistics on national photovoltaic power generation capacity and annual additions. Technical report, NEA, Beijing, 2026.

E. B. Pereira et al. Atlas brasileiro de energia solar. Technical report, INPE, São José dos Campos, 2017.

J. V. Queiroz et al. Barriers to expand solar photovoltaic energy in brazil. *Independent Journal of Management & Production*, 11(7): 2733–2756, 2020.

I. Reda and A. Andreas. Solar position algorithm for solar radiation applications. *Solar Energy*, 76(5):577–589, 2004.

E. Sarmas et al. Transfer learning strategies for solar power forecasting under data scarcity. *Scientific Reports*, 12:14643, 2022.

M. Suri et al. Global photovoltaic power potential by country. Technical report, World Bank, Washington, DC, 2020.

S. B. Taieb et al. A review and comparison of strategies for multi-step ahead time series forecasting based on the nn5 forecasting competition. *Expert Systems with Applications*, 39(8), 2012.

J. Tian, R. Ooka, and D. Lee. Multi-scale solar radiation and photovoltaic power forecasting with machine learning algorithms in urban environment: A state-of-the-art review. *Journal of Cleaner Production*, 426:139040, 2023.