INSTITUTO TECNOLÓGICO DE AERONÁUTICA



Pedro Arthur Sales Rebouças

DESENVOLVIMENTO DE UM MODELO DE PREVISÃO DE GERAÇÃO DE ENERGIA ELÉTRICA DE USINAS FOTOVOLTAICAS UTILIZANDO APRENDIZADO DE MÁQUINA

Trabalho de Graduação
2026

Curso de Engenharia Mecânica

CDU ???

Pedro Arthur Sales Rebouças

DESENVOLVIMENTO DE UM MODELO DE PREVISÃO DE GERAÇÃO DE ENERGIA ELÉTRICA DE USINAS FOTOVOLTAICAS UTILIZANDO APRENDIZADO DE MÁQUINA

Orientador

Prof. Dr. Rodrigo Arnaldo Scarpel (ITA)

ENGENHARIA MECÂNICA

São José dos Campos
Instituto Tecnológico de Aeronáutica

2026

Dados Internacionais de Catalogação-na-Publicação (CIP)
Divisão de Informação e Documentação

Rebouças, Pedro Arthur Sales
Desenvolvimento de um Modelo de Previsão de Geração de Energia Elétrica de Usinas Fotovoltaicas Utilizando Aprendizado de Máquina / Pedro Arthur Sales Rebouças.
São José dos Campos, 2026.
51f.

Trabalho de Graduação – Curso de Engenharia Mecânica– Instituto Tecnológico de Aeronáutica, 2026. Orientador: Prof. Dr. Rodrigo Arnaldo Scarpel.

1. Energia fotovoltaica. 2. Aprendizado de máquina. 3. Previsão de geração. 4. Séries temporais. I. Instituto Tecnológico de Aeronáutica. II. Título.

REFERÊNCIA BIBLIOGRÁFICA

REBOUÇAS, Pedro Arthur Sales. **Desenvolvimento de um Modelo de Previsão de Geração de Energia Elétrica de Usinas Fotovoltaicas Utilizando Aprendizado de Máquina**. 2026. 51f. Trabalho de Conclusão de Curso (Graduação) – Instituto Tecnológico de Aeronáutica, São José dos Campos.

CESSÃO DE DIREITOS

NOME DO AUTOR: Pedro Arthur Sales Rebouças
TITULO DO TRABALHO: Desenvolvimento de um Modelo de Previsão de Geração de Energia Elétrica de Usinas Fotovoltaicas Utilizando Aprendizado de Máquina.
TIPO DO TRABALHO/ANO: Trabalho de Conclusão de Curso (Graduação) / 2026

É concedida ao Instituto Tecnológico de Aeronáutica permissão para reproduzir cópias deste trabalho de graduação e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte deste trabalho de graduação pode ser reproduzida sem a autorização do autor.

Pedro Arthur Sales Rebouças
12.228-900 – São José dos Campos–SP

DESENVOLVIMENTO DE UM MODELO DE PREVISÃO DE GERAÇÃO DE ENERGIA ELÉTRICA DE USINAS FOTOVOLTAICAS UTILIZANDO APRENDIZADO DE MÁQUINA

Essa publicação foi aceita como Relatório Final de Trabalho de Graduação

---

Pedro Arthur Sales Rebouças

Autor

Rodrigo Arnaldo Scarpel (ITA)

Orientador

Prof. Dr. Nome do Coordenador
Coordenador do Curso de Engenharia Mecânica

São José dos Campos, de de 2026.

Dedique este trabalho a quem desejar.

Agradecimentos

Escreva aqui seus agradecimentos.

"Frase inspiradora opcional."
(Autor da frase)

Resumo

Escreva aqui o resumo em português (máximo 500 palavras, conforme ABNT NBR 6028:2021). O resumo deve apresentar de forma concisa os objetivos, metodologia, resultados e conclusões do trabalho.

Palavras-chave: energia fotovoltaica; aprendizado de máquina; previsão de geração; séries temporais; usinas solares.

Abstract

Write the abstract here (maximum 500 words, according to ABNT NBR 6028:2021). The abstract should present concisely the objectives, methodology, results and conclusions of the work.

Keywords: photovoltaic energy; machine learning; generation forecasting; time series; solar power plants.

Lista de Figuras

FIGURA 1.1 – De cima para abaixo: composição percentual da OIE para cada fonte de energia e composição percentual da matriz elétrica para cada fonte ambas para 2024. 19

FIGURA 1.2 – Evolução temporal da participação de cada fonte de energia na OIE(%) entre 2015 e 2024. 20

FIGURA 1.3 – Evolução da geração de energia elétrica por cada fonte. 20

FIGURA 1.4 – Mapas de produtividade fotovoltaica (PVOUT) do Brasil, Alemanha e China. 22

FIGURA 2.1 – Validação cruzada *K-fold* convencional, com particionamento aleatório que desconsidera a ordem cronológica. 46

FIGURA 2.2 – Validação cruzada em janela progressiva expansiva (*walk-forward*), em que o horizonte de treinamento cresce e o teste é sempre o bloco posterior. 47

FIGURA 2.3 – Validação cruzada em janela deslizante (*sliding window*), em que o conjunto de treinamento tem largura fixa e avança no tempo, descartando as observações mais antigas. 48

Lista de Tabelas

TABELA 1.1 – Geração de energia elétrica e capacidade instalada no Brasil, 2023–2024. 18

TABELA 1.2 – Comparativo de potencial solar, capacidade instalada e crescimento: Brasil, China e Alemanha. 24

TABELA 1.3 – Estimativa de ordem de grandeza do potencial de geração fotovoltaica do Nordeste para diferentes frações de ocupação territorial. . . 26

TABELA 2.1 – Comparativo das faixas de horizonte temporal de previsão de geração fotovoltaica. 40

Lista de Abreviaturas e Siglas

Lista de Abreviaturas e Siglas

Associação Brasileira de Normas Técnicas

Artificial Neural Network (Rede Neural Artificial)

Autoregressive Integrated Moving Average

Empresa de Pesquisa Energética

Fotovoltaico

Global Horizontal Irradiance (Irradiância Horizontal Global)

Instituto Tecnológico de Aeronáutica

Long Short-Term Memory

Mean Absolute Error (Erro Absoluto Médio)

Mean Absolute Percentage Error

Machine Learning (Aprendizado de Máquina)

Micro e Minigeração Distribuída

Numerical Weather Prediction (Previsão Numérica do Tempo)

Oferta Interna de Energia

Operador Nacional do Sistema Elétrico

Root Mean Square Error (Raiz do Erro Quadrático Médio)

Sistema Fotovoltaico

Standard Test Conditions (Condições Padrão de Ensaio)

Support Vector Machine

Usina Fotovoltaica

Extreme Gradient Boosting

Lista de Símbolos

Lista de Símbolos

Irradiância solar [W/m^2]

Irradiância horizontal global (GHI) [kWh/m^2/d]

Irradiância no plano dos módulos [W/m^2]

Irradiância extraterrestre no plano horizontal [W/m^2]

Índice de claridade (G_h/G_0)

Fração difusa (G_d/G_h)

Potência CA gerada [W]

Potência CC gerada [W]

Potência nominal da usina [W p]

Temperatura ambiente [°C]

Temperatura do módulo fotovoltaico [°C]

Eficiência do sistema fotovoltaico

Coeficiente de temperatura de potência [1/°C]

Valor previsto pelo modelo

Valor real observado

Horizonte de previsão

Sumário

1 Introdução 18

1.1 Cenário brasileiro de geração fotovoltaica 18

1.1.1 Dados atuais de geração 18

1.1.2 Comparação com outros países 21

1.1.3 Grande potencial ainda não totalmente aproveitado no Nordeste . . . 24

1.1.4 Empecilhos para aproveitar o potencial 26

1.1.5 Conexão com o trabalho apresentado e sua relevância 29

1.2 Objetivo do trabalho 31

1.3 Estrutura do texto 31

2 Referencial Teórico 32

2.1 Previsão de Geração de Energia Fotovoltaica 32

2.1.1 Especificidades para sistemas fotovoltaicos 32

2.1.2 Diferentes métodos de previsão 34

2.1.3 Horizontes temporais de previsão 37

2.1.4 Modelos de referência (*baselines*) 40

2.1.5 Abordagem utilizada 42

2.2 Aprendizado de Máquina para Séries Temporais 42

2.2.1 Fundamentos do aprendizado de máquina 42

2.2.2 *Cross-validation* para séries temporais 45

3 Materiais e Métodos 49

3.1 Dados Meteorológicos e Variáveis de Entrada 49

3.1.1 O conjunto de dados das usinas 49

3.1.2 Variáveis calculadas 49
3.1.3 Pré-processamento dos dados 49
3.1.4 Engenharia de *features* 49
3.1.5 Conjunto final de variáveis 49
3.2 Modelos Adotados 49
3.3 Métricas de Avaliação e *Benchmarks* 49

REFERÊNCIAS 50

1 Introdução

1.1 Cenário brasileiro de geração fotovoltaica

1.1.1 Dados atuais de geração

Segundo o Balanço Energético Nacional, divulgado em 2025 pela Empresa de Pesquisa Energética (EPE), a energia solar fotovoltaica consolidou-se como a fonte de maior crescimento da matriz brasileira nos últimos anos. Ao final de 2024, a capacidade instalada da fonte alcançou 48.468 GW, representando uma expansão de 28.1 % em relação ao ano anterior (Empresa de Pesquisa Energética, 2025). A geração de energia, consequentemente, também acompanhou esse ritmo, a produção solar fotovoltaica atingiu 70.7 TW h em 2024, crescimento de 39.6 % sobre 2023 (Empresa de Pesquisa Energética, 2025), conforme pode ser visto na Tabela 1.1.

TABELA 1.1 – Geração de energia elétrica e capacidade instalada no Brasil, 2023–2024.

Fonte: Empresa de Pesquisa Energética (2025).

Fonte	**2023**	**2024**	**Δ% 24/23**
Geração (GWh)			
Hidrelétrica	425.996	421.799	−1,0%
Gás Natural	38.589	47.792	23,9%
Eólica	95.801	107.654	12,4%
Biomassa	54.210	58.027	7,0%
Nuclear	14.504	15.767	8,7%
Carvão Vapor	8.770	10.247	16,8%
Derivados do Petróleo	5.686	5.960	4,8%
Solar Fotovoltaica	**50.633**	**70.665**	**39,6%**
Outras	13.932	13.425	−3,6%
Geração Total	**708.119**	**751.335**	**6,1%**
Capacidade Instalada (MW)			
Hidrelétrica	109.922	109.922	0,0%
Térmica	47.515	46.439	−2,3%
Nuclear	1.990	1.990	0,0%
Eólica	28.682	29.550	3,0%
Solar	**37.843**	**48.468**	**28,1%**
Capacidade Disponível	**225.952**	**236.370**	**4,6%**

Com efeito, ao caracterizar a inserção da fonte na matriz energética, é necessário distinguir dois indicadores frequentemente confundidos. Em relação à matriz elétrica nacional, na qual é contabilizada exclusivamente a geração de energia elétrica, a solar respondeu por 9.3 % do total em 2024 (Empresa de Pesquisa Energética, 2025). Já em relação à Oferta Interna de Energia (OIE), indicador mais amplo que abrange todas as formas de energia consumidas no país, incluindo combustíveis para transporte e processos industriais, a participação da fonte foi de 2.2 % (Empresa de Pesquisa Energética, 2025). A diferença entre os dois percentuais é esperada e decorre da distinta abrangência de cada indicador e ao explicitá-la evita-se interpretações equivocadas sobre o real peso da fonte no sistema energético como um todo.

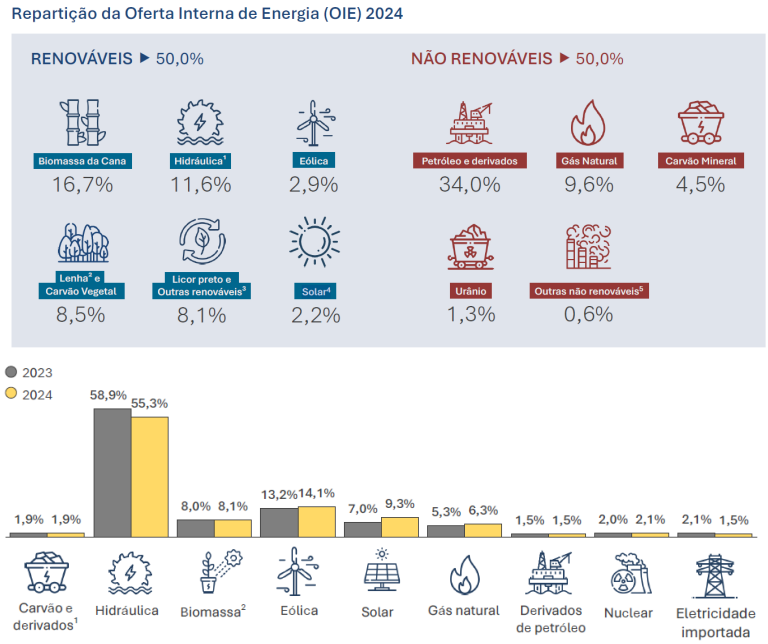


FIGURA 1.1 – De cima para abaixo: composição percentual da OIE para cada fonte de energia e composição percentual da matriz elétrica para cada fonte ambas para 2024.

Fonte: Empresa de Pesquisa Energética (2025).

Além disso, a energia fotovoltaica apresenta um elevado crescimento que torna-se evidente ao se analisar a série histórica. No âmbito da OIE, a participação da energia solar saltou de 0.2 % em 2015 para 2.2 % em 2024, configurando a fonte de maior crescimento percentual no período (Empresa de Pesquisa Energética, 2025). Esse avanço é impulsionado de forma expressiva pela micro e minigeração distribuída (MMGD), majoritariamente composta por sistemas fotovoltaicos, que já corresponde a cerca de 5.6 % de toda a geração elétrica do país (Empresa de Pesquisa Energética, 2025). Nesse sentido, os dados consolidados da evolução da participação das diferentes fontes na matriz elétrica e na OIE, são apresentados nas Figuras 1.2 e 1.3.

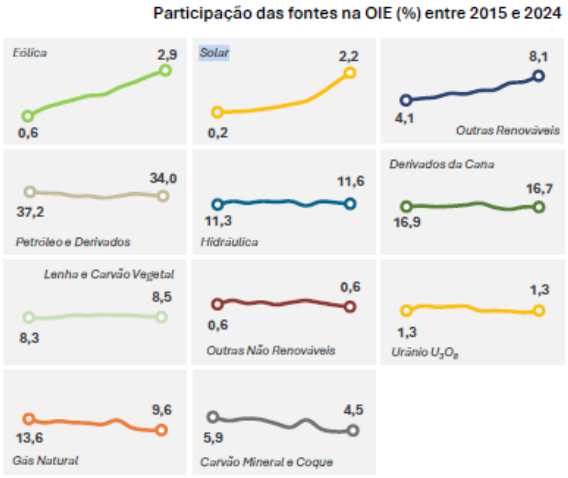


FIGURA 1.2 – Evolução temporal da participação de cada fonte de energia na OIE(%) entre 2015 e 2024.
Fonte:Empresa de Pesquisa Energética (2025)

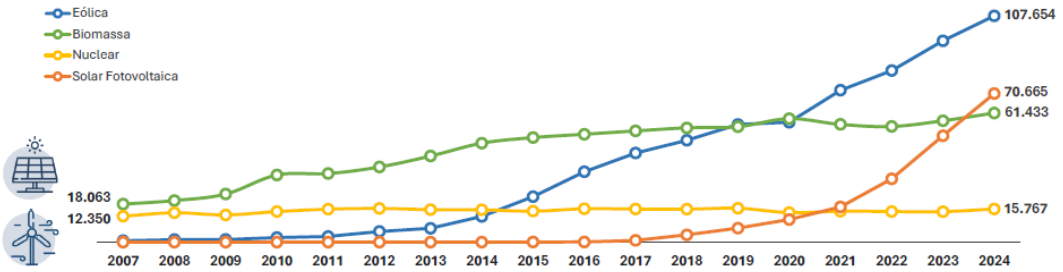


FIGURA 1.3 – Evolução da geração de energia elétrica por cada fonte.
Fonte:Empresa de Pesquisa Energética (2025)

Dados mais recentes confirmam a continuidade dessa trajetória. Segundo a Associação Brasileira de Energia Solar Fotovoltaica, a capacidade fotovoltaica operacional no país superou 70.3 GW em abril de 2026, considerando de forma agregada a geração centralizada e a distribuída (Associação Brasileira de Energia Solar Fotovoltaica, 2026). Cabe observar que esse valor não é diretamente comparável aos 48 468 MW reportados pelo Balanço Energético Nacional, uma vez que se refere a uma data de corte posterior (abril de 2026, ante dezembro de 2024) e adota o critério metodológico do Ministério de Minas e Energia, que adiciona à capacidade instalada de cada fonte as parcelas associadas de micro e minigeração distribuída. Independentemente do critério, ambos os indicadores apontam para a mesma tendência de expansão acelerada.

Esse crescimento já produz efeitos sistêmicos relevantes. Em 26 de dezembro de 2025, a fonte solar atingiu o recorde de 42 552 MW de geração instantânea, equivalente a 48.37 % da demanda nacional naquele momento; no mês de dezembro de 2025, respondeu por 15.23 % de toda a oferta de energia elétrica do país (Associação Brasileira de Energia Solar Fotovoltaica, 2026). Tal nível de penetração de uma fonte de caráter intermitente evidencia,

contudo, os desafios operacionais associados à sua variabilidade, os quais serão retomados na Subseção 1.1.5 como elemento central para a justificativa deste trabalho.

Dessa forma, os dados apresentados evidenciam que a energia fotovoltaica é uma fonte em ascensão, que em menos de uma década deixou de ser marginal para se tornar uma das protagonistas da expansão da matriz elétrica nacional. Esse desempenho expressivo, contudo, não decorre exclusivamente de incentivos regulatórios ou da redução de custos da tecnologia, mas encontra respaldo, sobretudo, nas condições físicas privilegiadas do território brasileiro para o aproveitamento da energia solar. Nesse sentido, para dimensionar adequadamente esse potencial e compreender o quanto dele ainda permanece inexplorado, faz-se necessário situar o Brasil no contexto internacional, comparando seus recursos e seu grau de aproveitamento com o de outros países.

1.1.2 Comparação com outros países

Apesar de expressiva, a expansão acelerada descrita na subseção anterior, ainda representa uma fração modesta do potencial físico do território brasileiro. No entanto, para dimensionar esse descompasso, é elucidativo confrontar o Brasil com duas das maiores potências fotovoltaicas mundiais em capacidade instalada que é China e Alemanha, distinguindo, primeiro, dois conceitos chaves: o *recurso solar disponível*, de natureza geográfica e climática, e o *grau de aproveitamento*, de natureza tecnológica, econômica e regulatória. Os indicadores de recurso utilizados nesta comparação provêm do estudo *Global Photovoltaic Power Potential by Country*, produzido pelo Banco Mundial em parceria com a Solargis (SURI *et al.*, 2020) e que padroniza, para fins de comparabilidade entre países, a irradiação horizontal global média (GHI, em $\mathrm{kWh/m^2/d}$) como medida do potencial teórico e a produtividade específica de uma usina de referência (PVOUT, em $\mathrm{kWh/kWp\,d}$) como medida do potencial prático.

A Alemanha é, historicamente, o país que pavimentou o mercado fotovoltaico mundial, mas o faz a despeito de um recurso solar reconhecidamente escasso. Segundo o estudo do Banco Mundial, o potencial teórico médio alemão é de apenas $2.978\,\mathrm{kWh/m^2/d}$ de GHI, ocupando a posição 197 no *ranking* mundial, ao passo que o Brasil registra $5.276\,\mathrm{kWh/m^2/d}$, ocupando a 89.ª posição (SURI *et al.*, 2020). Em termos de potencial prático, a produtividade média (PVOUT, nível 1) é de $2.961\,\mathrm{kWh/kWp/d}$ na Alemanha contra $4.404\,\mathrm{kWh/kWp/d}$ no Brasil (SURI *et al.*, 2020). A diferença é de tal ordem que o *máximo* potencial prático observado em território alemão ($3.33\,\mathrm{kWh/kWp/d}$) é inferior ao *mínimo* registrado em qualquer ponto do território brasileiro ($3.75\,\mathrm{kWh/kWp/d}$) (SURI *et al.*, 2020). Isto é, no local menos ensolarado do Brasil é possível gerar mais eletricidade solar do que no local mais ensolarado da Alemanha (**??**). A esse maior nível de irradiação soma-se uma vantagem qualitativa relevante para a operação do sistema que é a baixa sa-

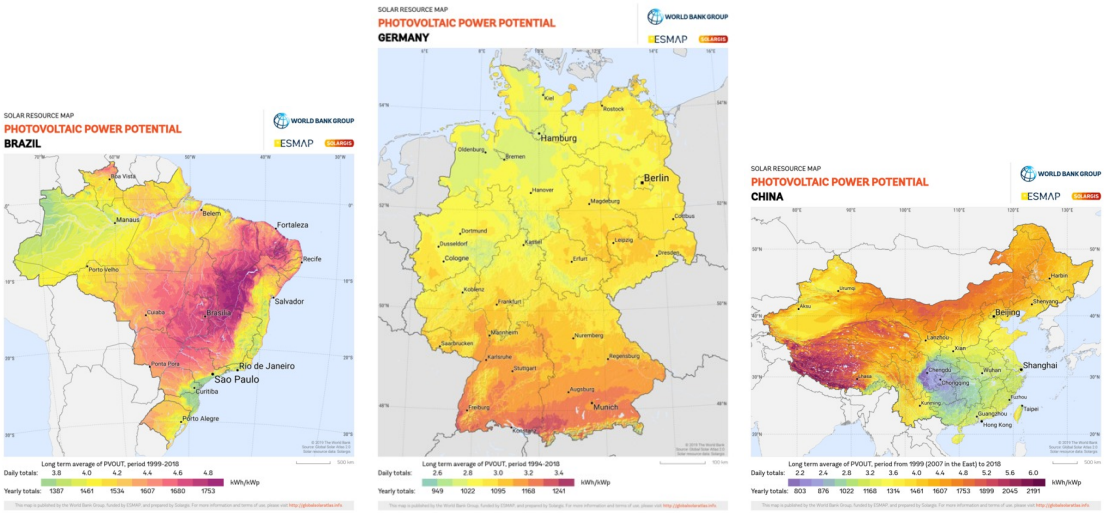


FIGURA 1.4 – Mapas de produtividade fotovoltaica (PVOUT) do Brasil, Alemanha e China.

zonalidade brasileira. Enquanto a razão entre o mês de maior e o de menor produtividade (índice de sazonalidade) atinge 4,37 na Alemanha, no Brasil esse índice é de apenas 1,34 (SURI *et al.*, 2020), o que se traduz em geração mais uniforme ao longo do ano e, portanto, em menor esforço de balanço sazonal por parte do operador do sistema.

Apesar dessa inferioridade de recursos, a Alemanha mantém uma das maiores bases instaladas do planeta, da ordem de 117 GW, com adições anuais médias próximas a 19.6 GW (Bundesministerium für Wirtschaft und Klimaschutz, 2025). Dessa forma, fica claro que o pioneirismo alemão decorreu não de condições naturais favoráveis, mas de políticas de incentivo de longo prazo — notadamente as tarifas *feed-in* —, de maturidade industrial e de previsibilidade regulatória. Essa constatação reforça que o aproveitamento da energia solar é determinado tanto pelo recurso disponível quanto pelos arranjos institucionais e tecnológicos que o viabilizam, dentre os quais se inclui a capacidade de prever a geração com precisão, tema central deste trabalho.

Já a China apresenta um perfil intermediário no que tange ao recurso, mas é, em larga margem, a líder absoluta em capacidade instalada. Seu potencial teórico médio é de 4.127 kWh/m^2 d de GHI (posição 161) e o potencial prático médio, de 3.883 kWh/kWp d de PVOUT (posição 151) (SURI *et al.*, 2020). Ambos os indicadores situam-se significativamente abaixo dos valores brasileiros (5.276 kWh/m^2/d e 4.404 kWh/kWp d, respectivamente), embora a heterogeneidade territorial chinesa seja notável, o oeste do país, sobretudo o Deserto de Gobi e o Planalto Tibetano, exibem valores de PVOUT comparáveis aos melhores sítios brasileiros, ao passo que as regiões orientais, mais populosas e industrializadas, apresentam produtividade bastante inferior. Em relação a sazonalidade, o país apresenta um índice de 1,67 (SURI *et al.*, 2020), sendo superior à brasileira, porém, ainda que mais favorável que a alemã.

No plano do aproveitamento, contudo, a assimetria se inverte de maneira dramática.

A China encerrou o período recente com capacidade fotovoltaica instalada da ordem de 1.23 TW, aproximadamente vinte vezes a base instalada brasileira, além de ter um crescimento anual em torno de 33.2 % e com previsão de adição de 180 GW a 240 GW ao longo de 2026 (National Energy Administration of China, 2026). Apenas a expansão chinesa projetada para um único ano supera, portanto, toda a capacidade fotovoltaica operacional no Brasil. O caso chinês evidencia uma faceta complementar à da Alemanha: trata-se de um país que não dispõe do melhor recurso solar, mas que, por meio de escala industrial, integração da cadeia produtiva e políticas de Estado, transformou a energia solar em pilar central de sua matriz elétrica.

A liderança chinesa, contudo, não se restringe à capacidade instalada em território próprio, uma verz que o país consolidou-se também como o centro nevrálgico da cadeia produtiva global de equipamentos fotovoltaicos. Em 2024, a China foi responsável por 93.2 % da produção mundial de polissilício, 96.6 % das lâminas (*wafers*), 92.3 % das células fotovoltaicas e 86.4 % dos módulos (DAVIDSON; QIAN, 2026). Essa concentração, somada à escala de produção, pressionou os preços dos módulos a mínimos históricos — frequentemente abaixo de 1 RMB/W —, tornando-os economicamente inviáveis para fabricantes de outras regiões (DAVIDSON; QIAN, 2026). Tal domínio reforça a constatação anterior de que o avanço chinês na geração apoia-se em uma posição dominante sobre toda a cadeia de valor, desde a matéria-prima até o produto final, o que situa o país não apenas como o maior gerador, mas como o principal fornecedor mundial da tecnologia. Cabe ressaltar, ainda, o vigor da expansão recente: somente em 2025 a China adicionou cerca de 315 GW de capacidade fotovoltaica (pv magazine, 2026), montante que, isoladamente, supera várias vezes toda a capacidade instalada acumulada pelo Brasil até o presente.

A Tabela 1.2 consolida os principais indicadores discutidos, contrastando o recurso solar disponível com o grau de aproveitamento em cada país.

A confrontação com Alemanha e China revela um quadro paradoxal. O Brasil reúne, simultaneamente, um recurso solar superior ao desses dois países com uma maior irradiação média e, sobretudo, uma menor sazonalidade, além de um grau de aproveitamento ainda incipiente quando medido em termos relativos, isto é, a área equivalente necessária para suprir todo o consumo elétrico nacional com geração fotovoltaica é estimada em apenas 0.03 % do território, contra 0.46 % da China e 2.95 % da Alemanha (SURI *et al.*, 2020), um indicador que sintetiza a folga existente entre potencial e exploração. Fica evidente, assim, que o gargalo brasileiro não reside no recurso natural, mas na capacidade de integrar de forma eficiente e confiável uma fonte de caráter intermitente a um sistema elétrico de dimensões continentais. É precisamente nesse ponto que se insere a contribuição deste trabalho uma previsão acurada da geração fotovoltaica constitui um elemento habilitador para que o vasto potencial brasileiro — particularmente o da região Nordeste, abordado na subseção seguinte — seja convertido em geração efetiva e despachável, mitigando os

TABELA 1.2 – Comparativo de potencial solar, capacidade instalada e crescimento: Brasil, China e Alemanha.

Indicador	**Brasil**	**China**	**Alemanha**
Recurso solar (longo prazo)[a]			
Potencial teórico (kWh/m^2/dia)	5,276	4,127	2,978
posição no ranking mundial	89.º	161.º	197.º
Potencial prático (kWh/kWp/dia)	4,404	3,883	2,961
posição no ranking mundial	84.º	151.º	197.º
Sazonalidade (−)	1,34	1,67	4,37
Área equivalente	0,03%	0,46%	2,95%
Aproveitamento (dados recentes)[b]			
Capacidade instalada	≈70,3 GW	≈1.230 GW	≈117 GW
Adição/crescimento recente	+28,1%/ano	+315 GW (2025)	+19,6 GW/ano

[a] Fonte: Suri *et al.* (2020), referente ao estudo *Global Photovoltaic Power Potential by Country* (dados de longo prazo, 2020).

[b] Capacidade do Brasil em abril de 2026 (Associação Brasileira de Energia Solar Fotovoltaica, 2026); capacidade e crescimento da China (National Energy Administration of China, 2026; pv magazine, 2026); capacidade e crescimento da Alemanha (Bundesministerium für Wirtschaft und Klimaschutz, 2025). O crescimento do Brasil refere-se à expansão da capacidade instalada em 2024 sobre 2023 (Empresa de Pesquisa Energética, 2025).

efeitos de sua variabilidade sobre a operação do sistema.

1.1.3 Grande potencial ainda não totalmente aproveitado no Nordeste

A vantagem brasileira evidenciada na comparação internacional não se distribui de modo homogêneo pelo território. Conforme atestado pela segunda edição do *Atlas Brasileiro de Energia Solar*, elaborado pelo Laboratório de Modelagem e Estudos de Recursos Renováveis de Energia (LABREN) do Instituto Nacional de Pesquisas Espaciais (INPE) a partir do modelo de transferência radiativa BRASIL-SR, a região Nordeste concentra os maiores níveis de irradiação solar do país (PEREIRA *et al.*, 2017). Os mapas de irradiação global horizontal (GHI) ali apresentados situam o semiárido nordestino, em especial o interior da Bahia e o vale do São Francisco, na faixa de maior incidência da escala nacional, com totais diários médios anuais que se aproximam do limite superior observado no território, da ordem de 6.5 kWh/m^2/d (PEREIRA *et al.*, 2017). Em termos de potencial prático, os dados do estudo *Global Photovoltaic Power Potential by Country* corroboram essa constatação, enquanto a mediana brasileira de PVOUT é de 4.42 kWh/kWp d, o valor máximo registrado no país alcança 4.92 kWh/kWp d, patamar associado justamente às áreas do Nordeste (SURI *et al.*, 2020).

A esse recurso de elevada magnitude soma-se uma característica de grande relevância para a operação de sistemas fotovoltaicos que é a baixa variabilidade sazonal. O regime de irradiação do semiárido é marcado por reduzida cobertura de nuvens e pequena oscilação

ao longo do ano, o que confere à região um índice de sazonalidade inferior ao da média nacional (PEREIRA *et al.*, 2017; SURI *et al.*, 2020). Tal estabilidade é tecnicamente desejável, pois implica geração mais uniforme entre as estações e, consequentemente, maior previsibilidade da produção energética, um atributo que, como se discutirá adiante, é determinante para a integração da fonte ao sistema elétrico.

Esse conjunto de fatores físicos explica a forte concentração da geração centralizada na região. De acordo com o levantamento mais recente da Associação Brasileira de Energia Solar Fotovoltaica, entre os estados com maior capacidade fotovoltaica centralizada outorgada figuram, logo após Minas Gerais, a Bahia (20 293.1 MW), o Piauí (17 388.1 MW), o Ceará (14 503.5 MW), o Rio Grande do Norte (9383.1 MW), a Paraíba (4087.2 MW) e Pernambuco (3812.1 MW) (Associação Brasileira de Energia Solar Fotovoltaica, 2026). Considerados em conjunto, os estados nordestinos respondem pela maior parcela da capacidade centralizada do país, refletindo a preferência dos empreendimentos de grande porte por sítios de elevada produtividade.

Subsiste, contudo, um descompasso expressivo entre o recurso disponível e o montante efetivamente convertido em geração, descompasso esse que tende a se agravar à medida que a capacidade instalada cresce mais rapidamente do que a infraestrutura de transmissão e os mecanismos de gestão da rede. Um indício concreto desse limite operacional já em curso é o aumento dos cortes de geração (*curtailment*) impostos às usinas solares: segundo o Operador Nacional do Sistema, as restrições de geração em usinas fotovoltaicas cresceram de forma acentuada nos últimos anos, alcançando, em 2025, montante equivalente a cerca de 20.7 % da geração (Associação Brasileira de Energia Solar Fotovoltaica, 2026). Em outras palavras, parcela relevante da energia que a região é fisicamente capaz de produzir deixa de ser injetada na rede, o que evidencia que o gargalo brasileiro — e nordestino em particular — reside não na disponibilidade do recurso, mas na capacidade de integrá-lo de forma confiável a um sistema elétrico de dimensões continentais.

Para dimensionar a ordem de grandeza desse potencial, é elucidativo um exercício de estimativa. Adotando-se a produtividade específica máxima reportada para o território nacional pelo *Global Photovoltaic Power Potential by Country*, de 4.92 kWh/kWp/d — equivalente a aproximadamente 1796 kWh/kWp ao ano (SURI *et al.*, 2020) — e uma densidade de potência instalada característica de usinas de grande porte com módulos fixos de silício cristalino, situada na faixa de 60 W p/m^2 a 75 W p/m^2 quando contabilizado o espaçamento entre fileiras[1], é possível estimar o potencial de geração associado à ocupação

[1]A densidade de potência considera a área total ocupada pela usina, incluindo o espaçamento entre fileiras de módulos necessário para evitar sombreamento mútuo, e não apenas a área ativa dos painéis. A produtividade específica refere-se a sistemas fixos com módulos monofaciais de silício cristalino e inclinação ótima, conforme a metodologia adotada em Suri *et al.* (2020). Trata-se de uma estimativa de ordem de grandeza, que não incorpora restrições de uso do solo, áreas de preservação, disponibilidade hídrica ou limitações da infraestrutura de transmissão.

de diferentes frações da área da região Nordeste, cuja extensão territorial é de cerca de $1.55 \times 10^6\,\mathrm{km}^2$.

Os resultados, sintetizados na Tabela 1.3, evidenciam a magnitude do recurso. A ocupação de apenas 1 % do território nordestino seria suficiente para gerar entre 1675 e 2093 TW h por ano, montante equivalente a cerca de 2.2 a 2.8 vezes toda a energia elétrica gerada no Brasil em 2024 (751 TW h). Caso a fração considerada fosse de 5 %, a geração teórica superaria em mais de dez vezes a produção nacional atual. Tais valores não representam, evidentemente, metas de implantação — são fisicamente irrealizáveis em sua totalidade —, mas explicitam a folga existente entre o recurso disponível e seu aproveitamento, bem como reforçam que a limitação ao avanço da fonte não é de natureza física, e sim operacional e sistêmica.

TABELA 1.3 – Estimativa de ordem de grandeza do potencial de geração fotovoltaica do Nordeste para diferentes frações de ocupação territorial.

Fonte: elaborado pelo autor a partir de Suri *et al.* (2020) e Empresa de Pesquisa Energética (2025). Premissas: PVOUT de 4.92 kWh/kWp/d (≈1796 kWh/kWp/); área do Nordeste de $1.55 \times 10^6\,\mathrm{km}^2$. Comparação: geração elétrica total do Brasil em 2024 = 751 TW h (Empresa de Pesquisa Energética, 2025).

Fração da área do Nordeste	**Densidade (W_p/m^2)**	**Capacidade (GW_p)**	**Geração anual (TWh/ano)**
1%	60	933	1.675
	75	1.166	2.093
5%	60	4.663	8.374
	75	5.829	10.467

1.1.4 Empecilhos para aproveitar o potencial

A análise das subseções anteriores deixa claro que o gargalo brasileiro para a expansão da geração fotovoltaica não reside na disponibilidade do recurso solar, mas em um conjunto de fatores de natureza operacional, técnica e institucional. A literatura especializada converge ao apontar que a distância entre o potencial físico e o efetivamente convertido em geração decorre de barreiras que extrapolam a dimensão econômica usualmente enfatizada (FRATEA; BRANNSTROM, 2017; QUEIROZ *et al.*, 2020). Dessa forma, discutem-se, nesta subseção, três desses empecilhos: a capacidade limitada da infraestrutura de transmissão, a escassez de mão de obra técnica qualificada e o ambiente tributário-regulatório, selecionados por sua relevância recorrente na literatura e por sua conexão direta com a justificativa deste trabalho.

Entre as barreiras de caráter técnico, a insuficiência da rede de transmissão é reiteradamente apontada como a mais crítica para a viabilização de empreendimentos de grande

porte. Nesse cenário, um estudo conduzido com agentes do setor elétrico do estado de Minas Gerais, Fratea e Brannstrom (2017) identificaram, por meio do método Q, que a percepção de que "a rede de transmissão de eletricidade não dispõe de capacidade para escoar a eletricidade solar que a geração fotovoltaica pode produzir" figura entre as barreiras estatisticamente mais significativas e mais bem ranqueadas pelos *stakeholders*. Para esse grupo, o gargalo de transmissão é considerado mais determinante do que o próprio preço ofertado nos leilões, sob o argumento de que a elevada irradiação de um sítio é condição necessária, mas não suficiente, à viabilidade do projeto: "usinas solares instaladas em locais de alta radiação não têm valor algum se não houver meio de escoar a energia" (FRATEA; BRANNSTROM, 2017). O mesmo estudo registra um caso emblemático em que uma usina projetada para gerar 2.78 MW de pico estava limitada por uma capacidade local de rede de apenas 1.25 MW (FRATEA; BRANNSTROM, 2017), ilustrando o descasamento entre a capacidade de geração e a de escoamento.

Esse diagnóstico, formulado em 2017, materializa-se hoje em um indicador concreto e crescente que é o corte de geração (*curtailment*). Conforme já mencionado na Subseção 1.1.3, as restrições de geração impostas às usinas fotovoltaicas pelo Operador Nacional do Sistema alcançaram, em 2025, montante equivalente a cerca de 20.7 % da geração total (Associação Brasileira de Energia Solar Fotovoltaica, 2026). Em outras palavras, a barreira de transmissão deixou de ser uma projeção teórica e tornou-se uma perda mensurável de energia já geráveis, agravada pelo fato de a expansão da capacidade instalada ocorrer em ritmo superior ao da ampliação das linhas de transmissão.

Um segundo empecilho, de natureza estrutural, é a carência de profissionais tecnicamente capacitados para sustentar o ciclo de vida dos sistemas fotovoltaicos. Fratea e Brannstrom (2017) relatam forte concordância entre os agentes do setor com a afirmação de que "a ausência de mão de obra especializada prejudica o desenvolvimento de usinas solares", justificada pela necessidade de capacidade técnica especializada "desde a concepção do projeto até a instalação, operação e manutenção". Um dos entrevistados adverte, de forma incisiva, que a falta de mão de obra qualificada "resultará em falhas operacionais, o que poderia favorecer tecnologias mais consolidadas, como a hidreletricidade" (FRATEA; BRANNSTROM, 2017) — observação particularmente relevante para este trabalho, na medida em que falhas operacionais e a baixa qualidade da operação comprometem diretamente a previsibilidade e a confiabilidade da geração.

Essa lacuna é igualmente apontada como uma das limitações intrínsecas da fonte em revisões da literatura, que listam a "falta de especialistas para manutenção, inspeção, reparo e avaliação" entre as principais barreiras ao aproveitamento da energia solar (QUEIROZ *et al.*, 2020). A dimensão do empecilho fica evidente no contraste internacional: na Alemanha, em 2013, o setor de energias renováveis já empregava mais de 370 000 trabalhadores em empregos diretos, número que ultrapassava 1.5 milhão quando consideradas as ativi-

dades de pesquisa, desenvolvimento, treinamento e educação associadas (QUEIROZ *et al.*, 2020). Cabe registrar, contudo, uma ressalva: parte da literatura argumenta que essa barreira é mitigável no médio prazo, dada a existência, em regiões de elevado potencial, de instituições de ensino técnico e superior capazes de formar a mão de obra necessária localmente (FRATEA; BRANNSTROM, 2017). Trata-se, portanto, de um empecilho real, porém endereçável por meio de políticas de qualificação profissional.

O terceiro grupo de empecilhos relaciona-se ao arcabouço tributário e regulatório. Por um lado, o marco regulatório foi historicamente o principal catalisador da expansão da fonte no país: a Resolução Normativa n.º 482/2012 da Agência Nacional de Energia Elétrica (ANEEL), ao regulamentar o sistema de compensação de energia da micro e minigeração distribuída, e os leilões específicos para usinas fotovoltaicas conduzidos pelo governo federal foram determinantes para o crescimento observado (URBANETZ *et al.*, 2018). Por outro lado, a própria literatura reconhece que a maturidade de mercados consolidados decorreu de instrumentos de incentivo de longo prazo — como as tarifas *feed-in* adotadas na Alemanha e na Espanha — combinados a reduções e isenções tributárias sobre equipamentos e sobre o lucro das empresas atuantes no setor (FRATEA; BRANNSTROM, 2017; QUEIROZ *et al.*, 2020).

No caso brasileiro, a carga tributária e os custos de capital ainda elevados contribuem para que o custo de implantação supere o de países de referência: em 2013, enquanto o custo de instalação na Alemanha era da ordem de 1684 €/kWp, no Brasil situava-se entre 2000 e 3000 €/kWp, isto é, praticamente o dobro (QUEIROZ *et al.*, 2020). Soma-se a isso a instabilidade do ambiente regulatório, frequentemente identificada como barreira política, uma vez que a incerteza quanto à manutenção das regras de incentivo eleva o risco percebido pelo investidor e inibe o aporte de capital no setor (QUEIROZ *et al.*, 2020; FRATEA; BRANNSTROM, 2017). Análises quantitativas das barreiras à expansão da fonte no país sugerem, inclusive, que as barreiras de natureza política e de conhecimento exercem influência superior à das barreiras estritamente financeiras, ambientais e sociais (QUEIROZ *et al.*, 2020), o que reforça a centralidade dos arranjos institucionais — e não apenas do custo da tecnologia — na explicação do aproveitamento ainda incipiente do potencial brasileiro.

Em suma, os três empecilhos discutidos compartilham uma característica comum: nenhum deles decorre de limitações do recurso solar, e todos se intensificam à medida que a participação de uma fonte intermitente cresce na matriz elétrica. A capacidade de transmissão, a disponibilidade de mão de obra e a estabilidade regulatória condicionam o quanto do potencial físico pode ser efetivamente convertido em geração confiável e despachável. É nesse contexto que se insere a contribuição deste trabalho, conforme se detalha na subseção seguinte.

1.1.5 Conexão com o trabalho apresentado e sua relevância

As subseções anteriores estabeleceram dois fatos centrais, primeiro, o Brasil dispõe de um recurso solar excepcional, particularmente no Nordeste, e, segundo, o aproveitamento desse recurso não é limitado por sua disponibilidade física, mas por barreiras de natureza operacional, técnica e institucional. Resta, portanto, articular de que modo um modelo de previsão de geração contribui para a superação dessas barreiras, articulação que constitui a justificativa central deste trabalho.

Nesse sentido, o ponto de partida é uma reinterpretação da própria natureza do problema. A intermitência da geração fotovoltaica, frequentemente tratada como uma limitação física intrínseca da fonte, é mais adequadamente compreendida como um problema de informação. Do ponto de vista da operação do sistema, a variabilidade da irradiância, causada por nebulosidade, sazonalidade e pelo próprio ciclo diário por exemplo, só se converte em risco operacional na medida em que é desconhecida ou mal estimada. O Operador Nacional do Sistema Elétrico (ONS) necessita saber, com antecedência suficiente, quanto cada usina irá gerar para programar o despacho complementar das demais fontes, dimensionar reservas e preservar o equilíbrio entre geração e carga. Quando essa informação é imprecisa ou indisponível, o operador é compelido a adotar uma postura conservadora, mantendo reservas térmicas girantes em operação permanente para fazer frente a desvios inesperados de geração. Tal solução é, simultaneamente, custosa, poluente e prejudicial à competitividade econômica da própria fonte solar, na medida em que parte de seu benefício ambiental e tarifário é anulada pela necessidade de respaldo térmico contínuo.

Sob essa ótica, melhorar a acurácia da previsão de geração equivale a reduzir a incerteza com que o operador trabalha e, por conseguinte, a margem de reserva que precisa manter. Tian, Ooka e Lee (2023) quantificam esse efeito de forma direta, afirmando que uma melhoria de 25 % na acurácia da previsão de geração fotovoltaica é capaz de reduzir o custo líquido de geração do sistema em 1.56 %, o que equivale a cerca de US$ 46,5 milhões por ano no caso analisado. Dessa forma, a relação evidencia que a previsão não é um exercício meramente acadêmico, mas um insumo operacional com efeitos econômicos mensuráveis. Cada incremento de acurácia se traduz em menor acionamento de reservas, menor custo de balanço e maior espaço para a injeção efetiva da geração solar na rede.

Esse mecanismo conecta-se diretamente aos empecilhos discutidos na Subseção 1.1.4. O *curtailment* crescente — que alcançou cerca de 20.7 % da geração fotovoltaica em 2025 (Associação Brasileira de Energia Solar Fotovoltaica, 2026) — decorre, em parte, da limitação física da transmissão, mas também da dificuldade do operador em coordenar, em tempo hábil, uma geração cuja trajetória não é conhecida com precisão suficiente. Uma previsão mais acurada não amplia, por si só, a capacidade das linhas, mas permite uma gestão mais

eficiente da capacidade existente, antecipando rampas de geração, otimizando o despacho hidrotérmico e reduzindo cortes motivados por margem de segurança excessiva.

A relevância desse aporte intensifica-se no contexto nordestino. Conforme discutido na Subseção 1.1.3, a região concentra a maior parcela da capacidade fotovoltaica centralizada do país e opera em estreita complementaridade com o parque hidrelétrico, cujos reservatórios são recorrentemente pressionados pelas secas cíclicas do semiárido. Nesse contexto, erros de previsão da geração solar propagam-se para o planejamento do despacho hidrotérmico, em que uma superestimação da geração fotovoltaica pode levar ao deplecionamento desnecessário de reservatórios, ao passo que uma subestimação implica acionamento térmico evitável. A precisão da previsão adquire, portanto, um valor sistêmico que extrapola a usina individual, condicionando a eficiência da operação integrada do subsistema.

A relevância da previsão, contudo, não se restringe à perspectiva do operador central. Do ponto de vista da iniciativa privada, como agentes geradores, comercializadores e investidores em ativos fotovoltaicos, a acurácia da previsão de geração incide diretamente sobre a receita e sobre a gestão do negócio. No ambiente de comercialização, o gerador precisa programar antecipadamente a energia que injetará na rede, e desvios entre a geração programada e a efetivamente realizada estão sujeitos a mecanismos de liquidação de diferenças que penalizam tanto a subentrega quanto a sobreentrega. Uma previsão mais acurada reduz a magnitude desses desvios e, por conseguinte, a exposição do agente a penalidades e à volatilidade do mercado de curto prazo, estabilizando o fluxo de receita do empreendimento.

Para além da dimensão comercial, a previsão qualifica o planejamento operacional do ativo. O conhecimento antecipado do perfil de geração subsidia o agendamento de paradas para manutenção em janelas de baixa produtividade, a operação coordenada com sistemas de armazenamento por baterias, cuja viabilidade econômica depende de uma estratégia de carga e descarga informada pela geração esperada, e a própria detecção de anomalias, na medida em que desvios sistemáticos entre a geração prevista e a observada podem sinalizar *soiling*, sombreamento ou falhas de equipamento.

Por fim, no horizonte do planejamento de longo prazo, modelos de previsão confiáveis reduzem a incerteza sobre a produção esperada e, com ela, o risco percebido pelo investidor, fator que — como discutido na Subseção 1.1.4 — influencia diretamente o custo de capital e a atratividade dos empreendimentos fotovoltaicos. Há, portanto, uma convergência de interesses, na qual a informação que torna a operação do sistema mais eficiente e barata para o operador é a mesma que melhora a previsibilidade financeira e a competitividade do gerador privado.

Em suma, este trabalho não se limita a desenvolver um modelo preditivo: ele produz

a informação de que o operador do sistema necessita, mas que ainda não dispõe com a qualidade adequada às especificidades do contexto brasileiro. É esse deslocamento, de um problema percebido como físico para um problema de informação tratável por meio de modelagem, que confere ao trabalho aplicação operacional concreta. Estando, dessa maneira, delimitado o problema e justificada sua relevância, resta enunciar os objetivos que orientam a investigação.

1.2 Objetivo do trabalho

1.3 Estrutura do texto

2 Referencial Teórico

2.1 Previsão de Geração de Energia Fotovoltaica

2.1.1 Especificidades para sistemas fotovoltaicos

A série temporal de geração de energia de uma usina fotovoltaica não constitui um sinal arbitrário: ela resulta da modulação de uma forçante astronômica determinística, a trajetória solar, por um conjunto de fatores atmosféricos de natureza estocástica. Dessa dupla origem decorre um conjunto de propriedades estatísticas particulares que distinguem o problema da previsão fotovoltaica de outras tarefas de previsão de séries temporais e que condicionam diretamente as escolhas de modelagem, de engenharia de *features* e de validação adotadas neste trabalho. Esta subseção discute quatro dessas especificidades.

A geração fotovoltaica exibe forte autocorrelação, isto é, dependência estatística entre valores da série separados por um intervalo de tempo. Em escalas curtas, essa dependência é elevada e decai monotonicamente com a defasagem, instantes consecutivos apresentam condições de irradiância e de carga muito semelhantes, de modo que a potência em um dado instante é fortemente preditiva da potência nos instantes imediatamente seguintes (ZHOU *et al.*, 2022). Essa propriedade é precisamente o que viabiliza as abordagens orientadas por dados, e fundamenta a construção de preditores baseados em defasagens (*lags*) e em médias móveis da série, que reintroduzem explicitamente essa memória temporal no vetor de entrada dos modelos. Importante salientar, contudo, que a autocorrelação não se restringe a defasagens curtas e dependendo do horizonte escolhido pode ser utilizado defasagens de mais de 24 horas.

A característica mais marcante da série de geração fotovoltaica é a presença de sazonalidade múltipla, ou seja, a superposição de ciclos periódicos de diferentes frequências. Dois ciclos predominam. O primeiro é o ciclo diário no qual a geração segue, a cada dia, um perfil aproximadamente em forma de sino, nulo durante a noite, crescente após o nascer do Sol, máximo ao redor do meio-dia solar e decrescente até o pôr do Sol. O segundo é o ciclo anual, a amplitude e a duração desse perfil diário variam ao longo do ano, em função da declinação solar e dos regimes sazonais de nebulosidade. A manifestação

conjunta dessas periodicidades é diretamente observável na distribuição temporal do erro dos modelos de previsão, que tende a ser maior nas horas centrais do dia e nos meses de maior irradiância, justamente onde a magnitude da geração é mais elevada (KAPPLER *et al.*, 2024). Essa estrutura sazonal determinística é, em grande medida, conhecida a priori e pode ser fornecida ao modelo por meio de variáveis astronômicas, como elevação, azimute e declinação solar, conforme adotado neste trabalho.

A potência gerada é uma grandeza fisicamente não-negativa e limitada superiormente pela capacidade nominal da usina. Mais relevante do ponto de vista estatístico é o fenômeno do truncamento diurno, ou seja, durante o período noturno, a geração é identicamente nula, o que faz com que uma fração substancial das observações da série assuma exatamente o valor zero, consequentemente, esse efeito distorce a distribuição da variável-alvo, tornando-a fortemente assimétrica e concentrada em zero, a ponto de que a mediana das observações pode situar-se próxima de zero quando as amostras noturnas são contabilizadas (ANDRADE *et al.*, 2023). Tal característica tem duas implicações metodológicas. A primeira diz respeito ao pré-processamento, no qual parte da literatura opta por remover as observações noturnas do conjunto de dados, tornando a série resultante mais homogênea e estacionária (KHALYASMAA *et al.*, 2020), enquanto outra parte as preserva, sob o argumento de que o modelo deve operar também nessas condições no cotidiano (ANDRADE *et al.*, 2023). A segunda implicação refere-se à própria saída do modelo na qual previsões fisicamente inconsistentes, como valores negativos ou geração noturna não nula, devem ser tratadas, seja por truncamento explícito a zero, seja pela imposição de limites dependentes do tempo derivados da geometria solar (MARKOVICS; MAYER, 2022).

Por fim, a série de geração fotovoltaica é não-estacionária: suas propriedades estatísticas, como média, variância e estrutura de autocorrelação, não permanecem constantes ao longo do tempo. Parte dessa não-estacionariedade é determinística e decorre das próprias sazonalidades já descritas, sendo, portanto, previsível. Outra parte, contudo, é induzida por fatores externos de evolução lenta ou abrupta, tais como a degradação progressiva dos módulos, o acúmulo de sujidade (*soiling*) sobre as superfícies, o sombreamento sazonal por obstáculos, falhas de equipamento e intervenções de manutenção. Esses fatores alteram a relação entre a forçante meteorológica e a potência efetivamente gerada, introduzindo mudanças no regime da série que não são explicáveis apenas pelas variáveis de entrada. Do ponto de vista da modelagem, a não-estacionariedade impõe cautela, uma vez que um modelo ajustado a um período pode degradar seu desempenho quando aplicado a um período posterior de regime distinto, o que reforça a necessidade de procedimentos de validação que respeitem a ordem cronológica dos dados — tema retomado na Subseção 2.2.2.

Em síntese, a previsão de geração fotovoltaica é um problema de série temporal de natureza particular, no qual uma estrutura determinística forte e conhecível, os ciclos solares, coexiste com uma componente estocástica e não-estacionária das condições at-

mosféricas e do estado das usinas. Dessa maneira, as decisões metodológicas adotadas neste trabalho, da seleção de variáveis à estratégia de validação, pode ser compreendida como uma resposta direta a essas quatro especificidades.

2.1.2 Diferentes métodos de previsão

A literatura especializada propõe diferentes taxonomias para organizar os métodos de previsão de geração fotovoltaica. Uma classificação recorrente, adotada por Andrade *et al.* (2023), distingue quatro classes: métodos físicos, estatísticos, de inteligência artificial e híbridos. Neste trabalho, contudo, adota-se a partição mais parcimoniosa proposta por (MARKOVICS; MAYER, 2022), na qual as abordagens de inteligência artificial são compreendidas como um subconjunto das estatísticas, resultando em três categorias: físicas, estatísticas e híbridas. Essa escolha decorre do fato de que tanto os modelos estatísticos clássicos quanto os de aprendizado de máquina compartilham a característica essencial de serem orientados por dados (*data-driven*), o que justifica seu agrupamento sob uma mesma categoria conceitual.

Antes de detalhar cada classe, convém estabelecer a notação comum. Seja $\hat{P}_{ac}(t+h)$ a previsão da potência elétrica em corrente alternada gerada pela usina no instante $t+h$, em que t é o instante de emissão da previsão e h o horizonte de previsão. As abordagens distinguem-se, essencialmente, pela forma como modelam o mapeamento entre as variáveis disponíveis no instante t e essa grandeza-alvo.

Os métodos físicos baseiam-se em cadeias de modelos (*model chains*) que descrevem analiticamente os processos envolvidos na conversão da energia solar em energia elétrica (MARKOVICS; MAYER, 2022). A entrada da cadeia é a irradiância prevista por modelos de Previsão Numérica do Tempo (*Numerical Weather Prediction* — NWP) ou estimada a partir de imagens de satélite (ANDRADE *et al.*, 2023). Por essa razão, a abordagem é também denominada indireta, pois a potência é obtida pela composição sucessiva de submodelos, e não diretamente a partir de dados de operação (MARKOVICS; MAYER, 2022).

Formalmente, a cadeia pode ser representada como uma composição de funções

$$\hat{P}_{ac} = (f_{\text{conv}} \circ f_{\text{trans}} \circ f_{\text{sep}})(G_h, \boldsymbol{\theta}), \tag{2.1}$$

em que G_h é a irradiância horizontal global (GHI) prevista e $\boldsymbol{\theta}$ reúne os parâmetros de projeto da usina, como orientação, inclinação, potência nominal e coeficientes do módulo. Cada operador corresponde a uma etapa física:

1. **Separação das componentes** (f_{sep}): decompõe a GHI em suas parcelas direta normal

(G_b) e difusa (G_d), uma vez que apenas a GHI costuma estar disponível. Modelos de separação estimam a fração difusa $k_d = G_d/G_h$ como função do índice de claridade $k_t = G_h/G_0$, sendo G_0 a irradiância extraterrestre no plano horizontal (MARKOVICS; MAYER, 2022).

2. **Transposição para o plano inclinado** (f_{trans}): converte as componentes no plano horizontal para a irradiância no plano dos módulos (G_t), geralmente segundo

$$G_t = G_b \cos\theta_i + G_d\, R_d + \rho\, G_h\, R_r, \tag{2.2}$$

em que θ_i é o ângulo de incidência, R_d e R_r são os fatores de transposição das componentes difusa e refletida, e ρ é o albedo do solo.

3. **Conversão irradiância-potência** (f_{conv}): modela a eficiência do sistema, incorporando o efeito da temperatura de operação. Uma forma usual é

$$P_{ac} = \eta_{\text{inv}}\, P_{\text{nom}}\, \frac{G_t}{G_{\text{STC}}}\left[1 + \gamma\,(T_{mod} - T_{\text{STC}})\right], \tag{2.3}$$

em que P_{nom} é a potência nominal, $G_{\text{STC}} = 1000$ W/m^2 e $T_{\text{STC}} = 25$ °C são as condições-padrão de ensaio (STC), $\gamma < 0$ é o coeficiente de temperatura de potência, η_{inv} a eficiência do inversor, e a temperatura do módulo T_{mod} é estimada a partir de T_{amb}, G_t e da velocidade do vento por correlações empíricas, e.g., $T_{mod} = T_{amb} + (G_t/G_{\text{ref}})\,(T_{\text{NOCT}} - 20)$ (SOHANI *et al.*, 2022).

Em aplicações de maior fidelidade, f_{conv} pode substituir a Equação (2.3) por um modelo eletricamente fundamentado do módulo, como o modelo de diodo único, cuja relação corrente-tensão é dada por

$$I = I_{ph} - I_0\left[\exp\!\left(\frac{V + IR_s}{nV_t}\right) - 1\right] - \frac{V + IR_s}{R_p}, \tag{2.4}$$

em que I_{ph} é a fotocorrente (proporcional a G_t), I_0 a corrente de saturação, V_t a tensão térmica, n o fator de idealidade, e R_s, R_p as resistências série e paralela (SOHANI *et al.*, 2022).

A principal vantagem dessa abordagem é não exigir dados históricos de operação, já que descreve o comportamento da usina a partir de seus parâmetros de projeto, os modelos físicos, portanto, podem ser implementados antes mesmo de a usina entrar em operação (ANDRADE *et al.*, 2023). Em contrapartida, apresentam, em geral, acurácia inferior à dos métodos orientados por dados e demandam conhecimento detalhado das especificações da planta (MARKOVICS; MAYER, 2022; ANDRADE *et al.*, 2023). Adicionalmente, a seleção dos submodelos que compõem cada elo da cadeia (separação, transposição e conversão)

exerce impacto considerável sobre a acurácia final (MARKOVICS; MAYER, 2022), e os erros de cada etapa propagam-se ao longo da composição da Equação (2.1).

Já os métodos estatísticos abrangem toda a gama de abordagens orientadas por dados, desde os modelos estatísticos clássicos até as técnicas de aprendizado de máquina (MARKOVICS; MAYER, 2022). O traço comum é estimar, a partir de um conjunto de dados históricos $\{(\mathbf{x}_i, y_i)\}_{i=1}^{N}$, uma função $\hat{f}$ que minimize uma função de perda $\mathcal{L}$ sobre esses dados,

$$\hat{f} = \arg\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\big(y_i, f(\mathbf{x}_i)\big), \tag{2.5}$$

sendo $\mathcal{F}$ a classe de funções admissíveis e, tipicamente, $\mathcal{L}$ o erro quadrático $\mathcal{L}(y, \hat{y}) = (y - \hat{y})^2$. A potência prevista é então $\hat{P}_{ac}(t + h) = \hat{f}(\mathbf{x}_t)$.

Os modelos diferenciam-se pela natureza do vetor de entrada $\mathbf{x}_t$ e pela classe $\mathcal{F}$. Nos modelos autorregressivos clássicos, como os da família ARIMA, a entrada é constituída pelos próprios valores passados da série de geração e dos erros passados. Um modelo ARMA(p, q), por exemplo, assume

$$y_t = c + \sum_{i=1}^{p} \phi_i \, y_{t-i} + \sum_{j=1}^{q} \vartheta_j \, \varepsilon_{t-j} + \varepsilon_t, \tag{2.6}$$

em que ϕ_i e ϑ_j são, respectivamente, os coeficientes autorregressivos e de média móvel, e ε_t é um ruído branco (ANDRADE *et al.*, 2023). Dessa forma, esses modelos são capazes de capturar dependências lineares na estrutura temporal da série, mas têm capacidade limitada de representar as relações fortemente não lineares entre as variáveis meteorológicas e a potência gerada.

Já os modelos de aprendizado de máquina (*machine learning*) ampliam a classe $\mathcal{F}$ para famílias não lineares e admitem como entrada um vetor de variáveis exógenas $\mathbf{x}_t$, como irradiância, temperatura ambiente, velocidade do vento e ângulos solares. Exemplos comuns na literatura de previsão fotovoltaica incluem máquinas de vetores de suporte (*Support Vector Machines*, SVM), florestas aleatórias (*Random Forests*) e redes neurais artificiais (ANDRADE *et al.*, 2023).

A principal vantagem operacional dos métodos estatísticos reside em não requererem conhecimento dos parâmetros de projeto da usina, o que facilita sua implementação (MARKOVICS; MAYER, 2022), sendo, dessa maneira, um atributo particularmente relevante para operadores que não dispõem das especificações de parques distribuídos. Entre eles, as técnicas de aprendizado de máquina são as mais empregadas (MARKOVICS; MAYER, 2022) e, embora frequentemente apresentem os melhores resultados, costumam exigir maior esforço computacional (ANDRADE *et al.*, 2023). Como limitações, herdam a dependência da quantidade e da qualidade dos dados de treinamento e estão sujeitas a sobreajuste

(*overfitting*) quando a complexidade de $\mathcal{F}$ não é adequadamente regularizada.

Por último, os métodos híbridos combinam elementos físicos e estatísticos em diferentes configurações, constituindo uma categoria abrangente que se refere à hibridização de quaisquer duas ou mais abordagens das classes anteriores (MARKOVICS; MAYER, 2022; ANDRADE *et al.*, 2023). Um exemplo representativo é o pré-processamento físico da irradiância prevista por modelos NWP como variável de entrada para um modelo de aprendizado de máquina. Nesse arranjo, a etapa física fornece uma estimativa fisicamente consistente da irradiância no plano dos módulos, G_t, e o modelo estatístico assume a conversão irradiância-potência, isto é,

$$\hat{P}_{ac}(t+h) = \hat{f}\big(f_{\text{trans}}(f_{\text{sep}}(G_h)), T_{amb}, V_w, \dots\big), \tag{2.7}$$

substituindo a conversão analítica das Equações (2.3)–(2.4) por um mapeamento aprendido dos dados.

Nesse cenário, a motivação é explorar a complementaridade entre as abordagens. Markovics e Mayer (2022) verificam que a incorporação, ao conjunto de preditores de um modelo de aprendizado de máquina, de variáveis calculadas analiticamente, como os ângulos de posição do Sol (elevação, azimute e declinação), aprimoram de forma significativa a acurácia das previsões de potência. Esse resultado evidencia que a fronteira entre as categorias é, na prática, permeável, e sugere que a engenharia de *features* de base física constitui uma forma de hibridização de baixo custo e elevado retorno.

2.1.3 Horizontes temporais de previsão

A previsão de geração fotovoltaica não constitui um problema único, mas uma família de problemas cujas variáveis de entrada relevantes, técnicas adequadas e aplicações de destino variam acentuadamente conforme o horizonte de previsão considerado, isto é, o intervalo de tempo entre o instante de emissão da previsão e o instante previsto. Conforme observam Tian, Ooka e Lee (2023), os valores de irradiância e de potência mantêm forte relação com a escala temporal, de modo que a definição do horizonte condiciona toda a estratégia de modelagem. A partir desse contexto, esta subseção apresenta, de forma comparativa, as principais faixas de horizonte usualmente distinguidas na literatura, situando ao final a opção adotada neste trabalho.

Com efeito, embora não exista uma fronteira universalmente padronizada entre as faixas, a literatura converge para uma divisão em quatro classes, sendo elas a previsão de altíssimo curto prazo (*nowcasting* ou intra-hora), a de curto prazo (intra-dia), a de um dia à frente (*day-ahead*) e a de médio a longo prazo. O traço que melhor as distingue não é apenas a duração, mas a natureza física dominante da incerteza em cada escala e, por

consequência, a fonte de informação mais adequada para reduzi-la.

Altíssimo curto prazo (nowcasting)

Nessa faixa, que abrange de segundos a aproximadamente uma hora à frente, a variabilidade da geração é governada quase exclusivamente pelo movimento de nuvens, que provoca rampas abruptas de irradiância em escala de segundos a minutos. Dessa maneira, as técnicas mais eficazes são as que capturam o estado instantâneo do céu, como imageadores de céu total (*sky imagers*), que extraem vetores de movimento de nuvens (*cloud motion vectors*) a partir de imagens hemisféricas, e modelos puramente autorregressivos baseados em medições de alta frequência da própria usina (TIAN; OOKA; LEE, 2023). Além disso, modelos de Previsão Numérica do Tempo (NWP), são inadequados nessa escala por sua resolução temporal e latência de processamento. As aplicações típicas incluem o controle em tempo real de inversores, a gestão de rampas e a operação coordenada com sistemas de armazenamento por baterias.

Curto prazo (intra-dia)

Estendendo-se de aproximadamente uma hora a seis horas à frente, essa faixa caracteriza-se, especialmente, pela transição entre o regime dominado por nuvens e aquele dominado pela dinâmica atmosférica de meso-escala. As abordagens mais empregadas combinam a extrapolação de imagens de satélite que oferecem cobertura espacial superior à dos imageadores de solo com modelos estatísticos e de aprendizado de máquina alimentados por séries temporais recentes (TIAN; OOKA; LEE, 2023). As aplicações estão associadas ao despacho intra-dia, ao mercado de curto prazo e ao balanceamento operacional do sistema.

Um dia à frente (day-ahead)

A previsão *day-ahead*, comumente entendida como o horizonte de 24 a 48 horas à frente, é a de maior relevância para a operação e a comercialização de energia, pois é a escala em que tipicamente se programa o despacho do dia seguinte e se submetem as ofertas ao mercado (MARKOVICS; MAYER, 2022). Nessa faixa, o movimento individual de nuvens já não é previsível de forma determinística, o que conduz a duas estratégias distintas quanto à informação utilizada. A primeira recorre à Previsão Numérica do Tempo (NWP), cujas previsões de irradiância e demais variáveis meteorológicas para o dia seguinte alimentam modelos de conversão irradiância-potência (MARKOVICS; MAYER, 2022). A segunda, de natureza puramente endógena, dispensa qualquer informação meteorológica futura e projeta a geração do dia seguinte exclusivamente a partir do histórico de geração e das variáveis medidas na própria usina até o instante de emissão da previsão, explorando a

estrutura de autocorrelação e os padrões diários e sazonais da série temporal. Diversos estudos da literatura adotam essa segunda estratégia, utilizando como preditores a potência gerada e as variáveis meteorológicas observadas em períodos anteriores (ANDRADE *et al.*, 2023).

A abordagem endógena apresenta a vantagem prática de não requerer acesso a previsões NWP ao custo de uma acurácia tipicamente inferior à da abordagem baseada em NWP, uma vez que se abstém da principal fonte de informação sobre as condições atmosféricas futuras. Trata-se, portanto, de um compromisso entre disponibilidade de dados e desempenho preditivo.

Médio e longo prazo

Para horizontes que vão de alguns dias a meses ou anos, a previsibilidade da geração em um instante específico essencialmente se perde, e o objeto da previsão desloca-se de valores instantâneos para grandezas agregadas como médias diárias, mensais, sazonais ou anuais (TIAN; OOKA; LEE, 2023). Predomina aqui a chamada previsão generalizada, na qual cada conjunto de entradas corresponde a um valor agregado de saída (TIAN; OOKA; LEE, 2023). As aplicações típicas situam-se no planejamento energético, no dimensionamento de ativos e na estimativa de produção de longo prazo para fins de análise de viabilidade.

Síntese comparativa

A Tabela 2.1 sintetiza as quatro faixas discutidas, contrastando o horizonte, a fonte física dominante da variabilidade, as técnicas predominantes e as principais aplicações.

A delimitação dessas faixas permite situar com precisão o escopo deste trabalho, que se concentra no horizonte de *um dia à frente* (*day-ahead*) sob uma abordagem estritamente endógena, isto é, baseada apenas no histórico das usinas, sem o emprego de previsões NWP.

Essa escolha justifica-se por dois motivos convergentes. Em primeiro lugar, o horizonte *day-ahead* é a escala de maior valor operacional e comercial, por coincidir com o horizonte de programação do despacho e de submissão de ofertas ao mercado, conforme discutido na Subseção 1.1.5. Em segundo lugar, a restrição a dados endógenos reflete uma condição realista de disponibilidade de dados no contexto brasileiro, no qual o acesso a previsões NWP de qualidade nem sempre está garantido, e permite avaliar em que medida a informação contida na própria série histórica das usinas é suficiente para uma previsão de utilidade operacional. Reconhece-se, contudo, que essa restrição estabelece um limite superior de acurácia inferior ao alcançável com a incorporação de previsões meteorológicas futuras, sendo, portanto, uma limitação assumida deliberadamente e discutida adiante na

TABELA 2.1 – Comparativo das faixas de horizonte temporal de previsão de geração fotovoltaica.

Faixa	**Horizonte típico**	**Técnicas predominantes**	**Aplicações principais**
Altíssimo curto prazo (*nowcasting*)	Segundos a ∼1 h	Imageadores de céu total, vetores de movimento de nuvens, modelos autorregressivos	Controle de inversores, gestão de rampas, operação de baterias
Curto prazo (intra-dia)	∼1 h a 6 h	Extrapolação de imagens de satélite, aprendizado de máquina	Despacho intra-dia, mercado de curto prazo, balanceamento
Um dia à frente (*day-ahead*)	24 h a 48 h	NWP acoplado a modelos de aprendizado de máquina, ou modelos puramente endógenos sobre séries históricas	Programação do despacho, comercialização no mercado diário
Médio e longo prazo	Dias a anos	NWP de longo alcance, modelos climatológicos, previsão generalizada	Planejamento energético, dimensionamento de ativos, análise de viabilidade

Fonte: elaborado pelo autor a partir de Markovics e Mayer (2022) e Tian, Ooka e Lee (2023).

análise de resultados.

2.1.4 Modelos de referência (*baselines*)

A avaliação de um modelo de previsão não se esgota na aferição de métricas como o erro quadrático médio (RMSE) ou o erro absoluto médio (MAE), discutidas na Seção 3.3, são fortemente dependentes das características do local, do horizonte e da resolução temporal dos dados, o que inviabiliza a comparação direta de resultados obtidos em conjuntos de dados distintos (MARKOVICS; MAYER, 2022). Um RMSE de determinado valor pode representar um desempenho excelente em um sítio de elevada variabilidade e medíocre em um sítio de céu estável. Por essa razão, a literatura de previsão solar recomenda contextualizar o desempenho de qualquer modelo por comparação com um modelo de referência (*baseline*), isto é, um método simples, de baixo custo, que estabelece o patamar mínimo de acurácia que um modelo sofisticado deve superar para justificar sua complexidade

(SARMAS *et al.*, 2022).

Essa comparação é formalizada pelo *índice de habilidade preditiva* (*forecast skill score*), definido como

$$\text{skill} = 1 - \frac{\text{RMSE}_{\text{modelo}}}{\text{RMSE}_{\text{ref}}}, \tag{2.8}$$

em que $\text{RMSE}_{\text{modelo}}$ é o erro do modelo proposto e RMSE_{ref} o do modelo de referência (SARMAS *et al.*, 2022). Um valor positivo indica que o modelo proposto supera o *baseline*, enquanto, um valor nulo, desempenho equivalente, e um valor negativo, inferior ao da referência. O *skill score* permite, assim, uma leitura padronizada e adimensional do ganho efetivo do modelo, ainda que se deva ressalvar que sua comparabilidade entre estudos distintos depende da adoção de uma mesma referência (MARKOVICS; MAYER, 2022). A seguir, apresentam-se os modelos de referência usualmente empregados na previsão de geração fotovoltaica.

Primeiro, tem-se o modelo de persistência ingênua (*naïve persistence*) é o mais elementar dos *baselines*. Assume que o valor futuro da grandeza é igual ao seu último valor observado,

$$\hat{y}(t + \Delta t) = y(t), \tag{2.9}$$

em que Δt é o horizonte de previsão. Embora seja um referencial trivial e de desempenho razoável em horizontes muito curtos, a persistência ingênua é manifestamente inadequada para a geração fotovoltaica em horizontes de horas ou mais, pois ignora por completo o ciclo diário da irradiância, ou seja, prevê que a geração das 18 h será igual à do meio-dia, produzindo, assim, erros grosseiros. Por isso, sua utilização isolada como referência é desencorajada na literatura de previsão solar, que a considera um patamar excessivamente baixo, capaz de superestimar artificialmente a habilidade do modelo avaliado (SARMAS *et al.*, 2022).

Para contornar essa limitação, a literatura recomenda o uso da persistência inteligente (*smart persistence*) como referência (SARMAS *et al.*, 2022), em que a ideia central é separar a componente determinística da geração, o ciclo solar, de sua componente estocástica, isto é, as flutuações associadas às condições atmosféricas. Define-se, primeiro, um modelo de céu claro (*clear-sky model*), que fornece a potência esperada $y_{cs}(t)$ que a usina geraria sob condições de céu limpo em cada instante, função determinística da hora do dia e do dia do ano. A persistência inteligente assume, então, que a razão entre a geração observada e a geração de céu claro, o chamado índice de céu claro, permanece constante ao longo do horizonte:

$$\hat{y}(t + \Delta t) = \begin{cases} y_{cs}(t + \Delta t), & \text{se } y_{cs}(t) = 0, \\ y_{cs}(t + \Delta t)\, \dfrac{y(t)}{y_{cs}(t)}, & \text{caso contrário,} \end{cases} \tag{2.10}$$

de modo que, em condições noturnas (quando $y_{cs}(t) = 0$), a previsão iguala-se à própria

potência de céu claro (SARMAS *et al.*, 2022). Essa formulação incorpora ao *baseline* a estrutura determinística do ciclo solar, elevando-o a um patamar de comparação muito mais exigente e fisicamente coerente. A persistência inteligente é, por isso, o modelo de referência recomendado e mais amplamente adotado na previsão de geração fotovoltaica (SARMAS *et al.*, 2022; MARKOVICS; MAYER, 2022). Cabe notar que o modelo de céu claro pode ser construído de forma empírica, por exemplo pela média dos valores históricos de potência condicionada à hora do dia e ao dia do ano (SARMAS *et al.*, 2022).

Além desses dois, há um terceiro grupo de referências, de complexidade intermediária, é composto por modelos estatísticos clássicos, como a regressão linear e os modelos autorregressivos da família ARIMA, já descritos na Subseção 2.1.2. No entanto, diferentemente da persistência, esses modelos são efetivamente ajustados aos dados, capturando dependências lineares na série e entre as variáveis. Seu papel como *baseline* é distinto do da persistência, pois enquanto esta estabelece o piso mínimo a ser superado, um modelo linear estabelece um referencial mais informativo, que isola especificamente o ganho atribuível à capacidade de modelar relações não lineares. Se um modelo de aprendizado de máquina não supera, ou supera apenas marginalmente, uma regressão linear sobre o mesmo conjunto de variáveis, há indício de que a complexidade adicional não se justifica para o problema em questão (MARKOVICS; MAYER, 2022).

A definição do conjunto de modelos de referência a ser efetivamente adotado neste trabalho é apresentada no Capítulo 3. De modo geral, a literatura sugere o emprego conjunto de *baselines* de diferentes níveis de sofisticação com a persistência inteligente como referência canônica que ancora o cálculo do *skill score* e assegura a comparabilidade com outros estudos da área e ao menos um modelo estatístico linear, que permite quantificar o ganho marginal proporcionado pela modelagem não linear. Essa estratificação dos referenciais confere robustez à avaliação, ao distinguir entre o ganho sobre um patamar trivial e o ganho sobre uma alternativa já não trivial.

2.1.5 Abordagem utilizada

2.2 Aprendizado de Máquina para Séries Temporais

2.2.1 Fundamentos do aprendizado de máquina

O aprendizado de máquina pode ser entendido como o conjunto de técnicas que permitem a um algoritmo melhorar seu desempenho em uma tarefa a partir da experiência adquirida com dados, sem que as regras de mapeamento sejam explicitamente programadas (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). A partir disso, no contexto deste trabalho, a tarefa é de aprendizado supervisionado, modalidade na qual o algoritmo dispõe, durante

o treinamento, de pares de entrada e saída $\{(x_i, y_i)\}_{i=1}^{N}$ e busca inferir a função subjacente que associa o vetor de preditores x_i ao valor-alvo y_i. Quando o alvo é uma grandeza contínua, por exemplo a potência ativa gerada pela usina, o problema configura-se como uma regressão, em oposição às tarefas de classificação, nas quais a saída é categórica (BISHOP, 2006). A particularidade do problema aqui tratado é que as observações constituem uma série temporal, isto é, uma sequência de medições indexadas no tempo e, em geral, mutuamente dependentes, o que impõe considerações específicas tanto na formulação quanto na avaliação dos modelos.

Conforme já formalizado na Equação (2.5), o ajuste de um modelo consiste em selecionar, dentro de uma classe de funções admissíveis $\mathcal{F}$, a função $\hat{f}$ que minimiza uma função de perda $\mathcal{L}$ sobre o conjunto de treinamento. O objetivo último do aprendizado, contudo, não é minimizar o erro sobre os dados já observados, mas sobre dados ainda não vistos. Formalmente, deseja-se minimizar o risco esperado, isto é, o valor esperado da perda sobre a distribuição conjunta $P(x, y)$ que governa o fenômeno,

$$R(f) = \mathbb{E}_{(x,y)\sim P}\big[\mathcal{L}\big(y, f(x)\big)\big]\,, \tag{2.11}$$

quantidade que não é diretamente acessível, dado que $P(x, y)$ é desconhecida. Na prática, minimiza-se o risco empírico, calculado sobre a amostra finita de treinamento, sob a hipótese de que este aproxima o risco esperado (VAPNIK, 1999). A discrepância entre ambos caracteriza a capacidade de generalização de um modelo, propriedade que distingue um sistema que efetivamente aprendeu padrões transferíveis de um que apenas memorizou as particularidades da amostra.

Nesse sentido, no caso das séries temporais, a validade dessa aproximação repousa sobre hipóteses que merecem atenção. Primeiramente, a formulação clássica do risco empírico pressupõe que as observações sejam independentes e identicamente distribuídas (*i.i.d.*), suposição evidentemente falsa em dados de geração fotovoltaica, uma vez que as medições consecutivas exibem forte autocorrelação, ou seja, a potência gerada em um instante guarda relação direta com a dos instantes vizinhos, além disso, a distribuição geradora dos dados não é, em rigor, estacionária, pois varia com os ciclos diário e sazonal e com a degradação dos equipamentos ao longo do tempo (HYNDMAN; ATHANASOPOULOS, 2021). Disso decorre que o desempenho aferido em dados passados só se transfere ao futuro na medida em que a estrutura estatística da série se mantenha aproximadamente estável, ressalva que delimita o alcance de qualquer previsão e que justifica a reavaliação periódica dos modelos em operação.

A formulação supervisionada de uma série temporal é tipicamente obtida pela construção de uma janela deslizante (*sliding window*), na qual o vetor de preditores x_t é composto por valores defasados da própria série e por covariáveis exógenas disponíveis

até o instante t, enquanto o alvo é o valor da série no horizonte de previsão $t + h$. Esse procedimento converte a sequência temporal em um conjunto de pares entrada-saída compatível com a Equação (**??**), mas introduz uma exigência crítica que nenhuma informação posterior ao instante de previsão pode integrar o vetor de preditores, sob pena de vazamento de informação (*data leakage*), que é o uso indevido de dados do futuro durante o treinamento, produzindo, assim, estimativas de desempenho otimistas e irrealizáveis em operação (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Essas considerações conectam-se ao compromisso entre viés e variância (*bias–variance tradeoff*), que organiza grande parte das decisões de modelagem. Modelos com capacidade representacional insuficiente, isto é, classe $\mathcal{F}$ excessivamente restrita, tendem a um erro sistemático elevado, ou alto viés, falhando em capturar a estrutura dos dados, fenômeno designado por subajuste (*underfitting*). Inversamente, modelos de capacidade excessiva ajustam-se ao ruído do conjunto de treinamento, exibindo alta variância e desempenho deficiente em dados novos, o já mencionado sobreajuste (*overfitting*) (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Dessa maneira, o erro esperado de generalização pode ser decomposto na soma de uma componente de viés ao quadrado, uma componente de variância e um termo de erro irredutível, associado ao ruído intrínseco do processo, este último inevitável e independente do modelo adotado (GEMAN; BIENENSTOCK; DOURSAT, 1992). No contexto deste trabalho, esse ruído incorpora a parcela genuinamente estocástica do fenômeno meteorológico subjacente, o que estabelece um piso de erro abaixo do qual nenhum modelo pode operar.

O controle desse compromisso é exercido, em larga medida, por meio da regularização que é um conjunto de técnicas que penalizam a complexidade do modelo a fim de restringir efetivamente a classe $\mathcal{F}$ e favorecer soluções mais simples e generalizáveis. Formalmente, para um modelo parametrizado por um vetor $\boldsymbol{\theta}$, o problema de minimização do risco empírico enunciado na Equação (2.5) é substituído por uma versão penalizada, em que se acresce à função de perda um termo $\Omega(\boldsymbol{\theta})$ que cresce com a complexidade do modelo,

$$\hat{\boldsymbol{\theta}} = \arg\min_{\boldsymbol{\theta}} \left[\frac{1}{N} \sum_{i=1}^{N} \mathcal{L}\big(y_i,\, f(x_i; \boldsymbol{\theta})\big) + \lambda\, \Omega(\boldsymbol{\theta}) \right], \tag{2.12}$$

em que $\lambda \geq 0$ é um hiperparâmetro que pondera o compromisso entre a fidelidade aos dados de treinamento, favorecida pelo primeiro termo, e a simplicidade do modelo, favorecida pelo segundo. O limite $\lambda \to 0$ recupera a minimização do risco empírico sem penalização, ficando, assim, propensa ao sobreajuste, ao passo que valores elevados de λ restringem mais severamente a classe efetiva de funções, deslocando o modelo na direção de maior viés e menor variância. A regularização constitui, dessa maneira, o mecanismo explícito pelo qual o compromisso viés-variância é operacionalizado durante o ajuste. As escolhas mais usuais para o termo de penalidade incidem sobre a norma do vetor de parâmetros.

A penalidade ℓ_2 (*ridge*), $\Omega(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_2^2 = \sum_j \theta_j^2$, encolhe os coeficientes de forma contínua em direção a zero, sem necessariamente anulá-los, mitigando a sensibilidade do modelo a variáveis correlacionadas. Já a penalidade ℓ_1 (*lasso*), $\Omega(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_1 = \sum_j |\theta_j|$, tende a produzir soluções esparsas, anulando inteiramente os coeficientes de preditores pouco informativos e operando, por conseguinte, uma forma implícita de seleção de variáveis (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Além dessas penalidades aplicadas diretamente à função de perda, há mecanismos de regularização específicos de cada família de modelos, tais como a limitação da profundidade em árvores de decisão ou a interrupção antecipada (*early stopping*) no treinamento de redes neurais.

Em síntese, a busca por generalização para além do conjunto de treinamento, o compromisso entre viés e variância e o controle da complexidade por regularização convergem para uma mesma exigência prática de estimar de forma confiável o desempenho de um modelo sobre dados ainda não vistos, tanto para selecionar seus hiperparâmetros quanto para aferir sua acurácia final. Tal estimativa demanda um protocolo que mantenha rigorosamente separados os dados empregados no ajuste e os reservados para avaliação. No caso de séries temporais, contudo, a dependência entre observações e a ordenação cronológica impõem que essa separação respeite a ordem cronológica dos dados, sob o risco de resultar em um *data leakage*. Dessa forma, a seção 2.2.2 examina como os procedimentos de validação cruzada (*cross-validation*) devem ser adaptados a esse contexto, de modo a produzir estimativas de desempenho metodologicamente válidas e representativas das condições reais de operação.

2.2.2 *Cross-validation* para séries temporais

A estimativa confiável do desempenho de generalização, motivada ao final da Subseção 2.2.1, é tradicionalmente obtida por validação cruzada (*cross-validation*). Em sua forma canônica, a validação cruzada em K partições (K-*fold*) divide aleatoriamente o conjunto de dados em K subconjuntos de tamanho aproximadamente igual a cada iteração e $K-1$ partições são empregadas no treinamento do modelo enquanto a partição restante, apenas na avaliação, repetindo-se o procedimento K vezes de modo que cada observação seja utilizada exatamente uma vez para teste. Ao final do processo, a média das métricas de erro sobre as K iterações fornece uma estimativa de desempenho menos sensível a uma divisão particular dos dados do que a obtida por uma única partição treino-teste, além de aproveitar integralmente o conjunto disponível para avaliação (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

O pressuposto que sustenta o particionamento aleatório, contudo, é justamente o da independência entre as observações, a mesma hipótese *i.i.d.* cuja inadequação às séries temporais foi discutida na Subseção 2.2.1. Conforme ilustra a Figura 2.1, o K-*fold* con-

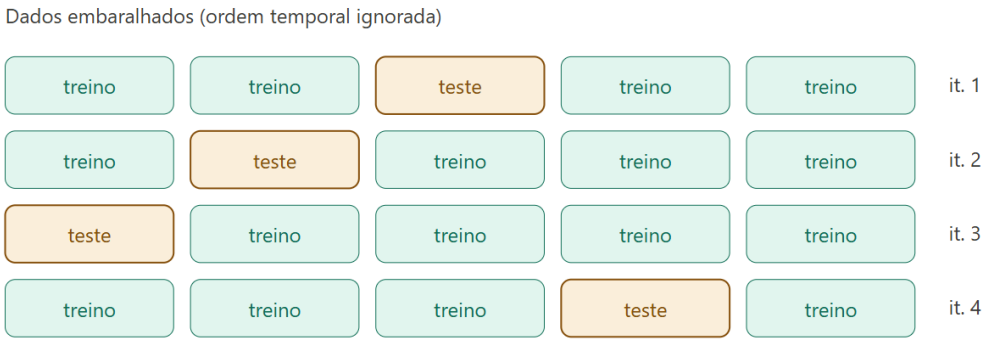


FIGURA 2.1 – Validação cruzada *K-fold* convencional, com particionamento aleatório que desconsidera a ordem cronológica.

Fonte: Elaborada pelo autor.

vencional permite, ao embaralhar a ordem cronológica, que observações posteriores ao instante de previsão componham o conjunto de treinamento enquanto observações anteriores integram o conjunto de teste, o que configuram, dessa forma, um vazamento de informação (*data leakage*) já caracterizado. Em uma série fortemente autocorrelacionada, amostras temporalmente vizinhas são quase redundantes, de modo que treinar com o futuro para prever o passado produz estimativas de erro artificialmente otimistas, que não se reproduzem quando o modelo é colocado em operação e dispõe apenas de informação pretérita (HYNDMAN; ATHANASOPOULOS, 2021).

O contexto trabalhado exige, portanto, uma adaptação dos procedimentos de validação de tal forma que toda partição respeite a ordenação temporal, dessa forma, o conjunto de avaliação deve ser sempre posterior ao conjunto de treinamento, reproduzindo, assim, a assimetria entre passado e futuro inerente à tarefa de previsão. Nesse sentido, a forma mais simples consiste em uma única divisão cronológica, na qual os dados mais antigos são reservados ao ajuste e o período mais recente, à avaliação, sendo essa estratégia adotada, por exemplo, por Kappler *et al.* (2024), que destinam seis anos de operação ao treinamento e o ano subsequente à validação. Tal divisão única, no entanto, avalia o modelo sobre um único período e fica sujeita às particularidades meteorológicas daquele intervalo, o que limita a robustez da estimativa.

Para mitigar essa limitação preservando a causalidade temporal, emprega-se a validação cruzada para séries temporais, em que a avaliação é repetida sobre múltiplas divisões cronológicas sucessivas. Na variante de janela progressiva expansiva (*walk-forward* ou *forward chaining*), ilustrada na Figura 2.2, o horizonte de treinamento é ampliado a cada iteração, incorporando as observações da iteração anterior, e o desempenho é medido sempre sobre o bloco imediatamente posterior, simulando o uso real do modelo, no qual novas observações tornam-se disponíveis com o passar do tempo. Dessa maneira, as métricas obtidas nos sucessivos blocos de teste são então agregadas, oferecendo uma estimativa de generalização que combina a robustez da repetição com o rigor da separação temporal

(HYNDMAN; ATHANASOPOULOS, 2021). Uma forma particular dessa estratégia, adequada a dados sazonais, é a adotada por Markovics e Mayer (2022), que particionam a série em blocos anuais e avaliam o modelo ajustado a um ano sobre outro ano distinto, assegurando que treinamento e teste cubram ciclos sazonais completos.

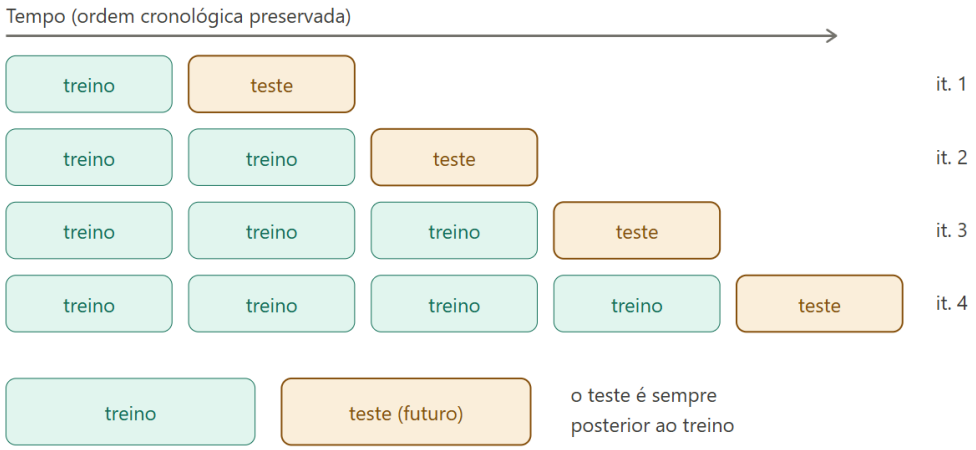


FIGURA 2.2 – Validação cruzada em janela progressiva expansiva (*walk-forward*), em que o horizonte de treinamento cresce e o teste é sempre o bloco posterior.

Fonte: Elaborada pelo autor.

Uma alternativa à janela expansiva é a janela deslizante (*sliding window*), representada na Figura **??**, na qual o conjunto de treinamento mantém largura fixa e avança como um bloco rígido ao longo do tempo, descartando as observações mais antigas à medida que incorpora as mais recentes. A distinção entre as duas variantes não é meramente operacional, mas reflete uma hipótese sobre a estrutura dos dados. A janela expansiva aproveita todo o histórico disponível, reduzindo a variância das estimativas e favorecendo modelos de maior complexidade paramétrica, que demandam mais dados para o ajuste, ao mesmo tempo, que pressupõe que os regimes passados permaneçam representativos do futuro. Dessa forma, ao descartar deliberadamente o passado distante, a janela deslizante torna-se mais reativa a mudanças de regime e mais fiel à condição operacional recente, ao custo de treinar sempre com uma amostra menor. No entando, essa propriedade é particularmente pertinente à previsão de geração fotovoltaica, na qual a degradação gradual dos módulos e eventuais intervenções de manutenção introduzem não-estacionariedade na série, conforme discutido na Subseção 2.2.1, podendo tornar contraproducente o uso de dados muito antigos no ajuste.

Cabe ressaltar que a validação cruzada cumpre, neste trabalho, dupla função de estimar o desempenho final do modelo sobre dados não vistos, além de ser o instrumento pelo qual se conduz a seleção de hiperparâmetros. Para que essa estimativa permaneça imparcial, é necessário evitar que os dados empregados no ajuste dos hiperparâmetros contaminem a avaliação do desempenho final, o que motiva a segregação entre conjuntos de treinamento, e teste ou, no caso das ANN, treino, validação e teste. A definição do

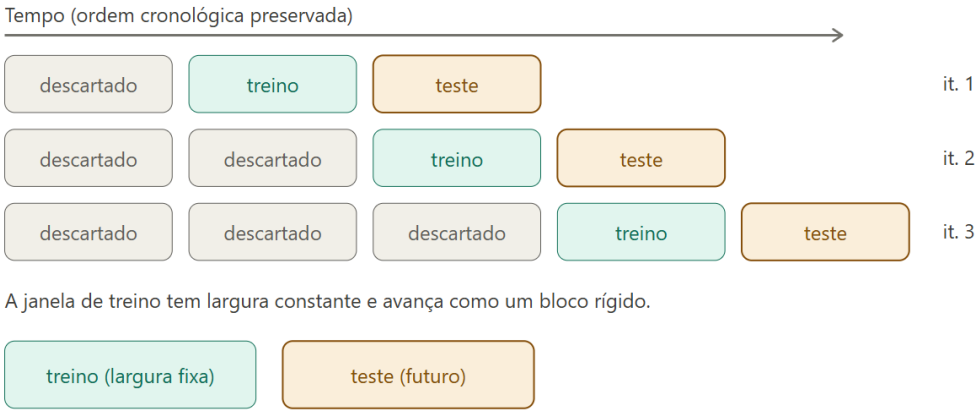


FIGURA 2.3 – Validação cruzada em janela deslizante (*sliding window*), em que o conjunto de treinamento tem largura fixa e avança no tempo, descartando as observações mais antigas.

Fonte: Elaborada pelo autor.

protocolo efetivamente adotado, incluindo a variante de janela, o número de partições e a extensão dos blocos temporais, é apresentada no Capítulo 3.

3 Materiais e Métodos

3.1 Dados Meteorológicos e Variáveis de Entrada

3.1.1 O conjunto de dados das usinas

3.1.2 Variáveis calculadas

3.1.3 Pré-processamento dos dados

3.1.4 Engenharia de *features*

3.1.5 Conjunto final de variáveis

3.2 Modelos Adotados

3.3 Métricas de Avaliação e *Benchmarks*

Referências

ANDRADE, C. H. T. d. *et al.* How does neural network model capacity affect photovoltaic power prediction? a study case. **Sensors**, v. 23, n. 3, p. 1357, 2023

Associação Brasileira de Energia Solar Fotovoltaica. **Infográfico ABSOLAR nº 91: energia solar fotovoltaica no Brasil**. São Paulo: [*s.n.*], 5 2026. `https://www.absolar.org.br/mercado/infografico/`. Acesso em: 1 jun. 2026

BISHOP, C. M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006

Bundesministerium für Wirtschaft und Klimaschutz. **Erneuerbare Energien in Deutschland: Daten zur Entwicklung der Photovoltaik**. Berlin: [*s.n.*], 2025. `https://www.bmwk.de/`. Ministério Federal da Economia e Proteção Climática da Alemanha. Acesso em: 1 jun. 2026

DAVIDSON, M.; QIAN, S. **China's Solar Industry Is in Upheaval – The Effects Will Be Global**. Washington, DC, 3 2026. Available at: https://www.csis.org/

Empresa de Pesquisa Energética. **Balanço Energético Nacional 2025: Relatório Síntese – Ano base 2024**. Rio de Janeiro, 2025. Available at: https://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/balanco-energetico-nacional-2025

FRATEA, C. A.; BRANNSTROM, C. Stakeholder subjectivities regarding barriers and drivers to the introduction of utility-scale solar photovoltaic power in Brazil. **Energy Policy**, v. 111, p. 346–352, 2017

GEMAN, S.; BIENENSTOCK, É.; DOURSAT, R. Neural networks and the bias/variance dilemma. **Neural Computation**, v. 4, n. 1, p. 1–58, 1992

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: Principles and Practice**. 3. ed. Melbourne: OTexts, 2021

KAPPLER, T. *et al.* Detection of shading for short-term power forecasting of photovoltaic systems using machine learning techniques. **EPJ Photovoltaics**, v. 15, p. 17, 2024

KHALYASMAA, A. I. *et al.* Industry experience of developing day-ahead photovoltaic plant forecasting system based on machine learning. **Remote Sensing**, v. 12, n. 20, p. 3420, 2020

MARKOVICS, D.; MAYER, M. J. Comparison of machine learning methods for photovoltaic power forecasting based on numerical weather prediction. **Renewable and Sustainable Energy Reviews**, v. 161, p. 112364, 2022

National Energy Administration of China. **Statistics on national photovoltaic power generation capacity and annual additions**. Beijing: [*s.n.*], 2026. `http://www.nea.gov.cn/`. Administração Nacional de Energia da China. Acesso em: 1 jun. 2026

PEREIRA, E. B. *et al.* **Atlas Brasileiro de Energia Solar**. 2. ed. São José dos Campos: INPE, 2017. Available at: http://labren.ccst.inpe.br/atlas$_2$017.*html*

pv magazine. **China adds 315 GW of solar in 2025**. 1 2026. `https://www.pv-magazine.com/2026/01/28/china-adds-315-gw-of-solar-in-2025/`. Acesso em: 1 jun. 2026

QUEIROZ, J. V. *et al.* Barriers to expand solar photovoltaic energy in Brazil. **Independent Journal of Management & Production**, v. 11, n. 7, p. 2733–2756, 2020

SARMAS, E. *et al.* Transfer learning strategies for solar power forecasting under data scarcity. **Scientific Reports**, v. 12, p. 14643, 2022

SOHANI, A. *et al.* Using machine learning in photovoltaics to create smarter and cleaner energy generation systems: A comprehensive review. **Journal of Cleaner Production**, v. 364, p. 132701, 2022

SURI, M. *et al.* **Global Photovoltaic Power Potential by Country**. Washington, DC, 2020. Available at: https://globalsolaratlas.info/global-pv-potential-study

TIAN, J.; OOKA, R.; LEE, D. Multi-scale solar radiation and photovoltaic power forecasting with machine learning algorithms in urban environment: A state-of-the-art review. **Journal of Cleaner Production**, v. 426, p. 139040, 2023

URBANETZ, I. V. *et al.* Panorama atual e cenário 2025 da energia solar fotovoltaica no Brasil. *In*: **Anais do Smart Energy**. **Proceedings** [...]. Curitiba: [*s.n.*], 2018

VAPNIK, V. N. **The Nature of Statistical Learning Theory**. 2. ed. New York: Springer, 1999

ZHOU, N. *et al.* Spatio-temporal probabilistic forecasting of photovoltaic power based on monotone broad learning system and copula theory. **IEEE Transactions on Sustainable Energy**, v. 13, n. 4, p. 1874–1885, 2022

FOLHA DE REGISTRO DO DOCUMENTO

1. CLASSIFICAÇÃO/TIPO	2. DATA	3. DOCUMENTO Nº	4. Nº DE PÁGINAS
TC	2026	DCTA/ITA/TG-???/2026	51

5. TÍTULO E SUBTÍTULO:
Desenvolvimento de um Modelo de Previsão de Geração de Energia Elétrica de Usinas Fotovoltaicas Utilizando Aprendizado de Máquina

6. AUTOR(ES):
Pedro Arthur Sales Rebouças

7. INSTITUIÇÃO(ÕES)/ÓRGÃO(S) INTERNO(S)/DIVISÃO(ÕES):
Instituto Tecnológico de Aeronáutica – ITA

8. PALAVRAS-CHAVE SUGERIDAS PELO AUTOR:
Energia fotovoltaica; Aprendizado de máquina; Previsão de geração

9. PALAVRAS-CHAVE RESULTANTES DE INDEXAÇÃO:
Energia fotovoltaica; Aprendizado de máquina; Séries temporais; Usinas solares

10. APRESENTAÇÃO: (**X**) **Nacional** ( ) **Internacional**
Trabalho de Graduação, ITA, São José dos Campos, 2026. 51 páginas.

11. RESUMO:
Escreva aqui o resumo em português (máximo 500 palavras, conforme ABNT NBR 6028:2021). O resumo deve apresentar de forma concisa os objetivos, metodologia, resultados e conclusões do trabalho.

Palavras-chave: energia fotovoltaica; aprendizado de máquina; previsão de geração; séries temporais; usinas solares.

12. GRAU DE SIGILO:
(**X**) **OSTENSIVO** ( ) **RESERVADO** ( ) **SECRETO**